

利润最大化


$$\max_{x_1, x_2} 40x_1 + 50x_2$$

$$s.t. x_1 + 2x_2 \leq 40$$

$$4x_1 + 3x_2 \leq 120$$

$$x_1 \geq 0$$

$$x_2 \geq 0$$



1.1.4 稀疏向量

- 如果一个向量的许多项都是0, 该向量为**稀疏(Sparse)**的。
- 稀疏向量能在计算机上高效地存储和操作。
- $\text{nnz}(x)$ 是指向量 x 中非零的项数(number of non-zeros), 有时用 ℓ_0 表示。
- 例子: 零向量 0_3 , 单位向量 e_2 。

$$0_3 = \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix}, \quad e_2 = \begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix}$$

1.2 数域

\mathbb{Q}	\mathbb{R}	\mathbb{C}
有理数	实数	复数
$\frac{1}{3}$	π	$1+i$

数域: 数的非空集合 P , 且其中任意两个数的和、差、积、商(除数不为零)仍属于该集合, 则称数集 P 为一个数域。

例如: $x, y \in \mathbb{R}, x = 1, y = 2.$

$$x + y \in \mathbb{R} \quad x \times y \in \mathbb{R}$$

实数 x 加(乘)实数 y : 结果 $x+y$ ($x \times y$)是实数

1.2 向量空间

$$x = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} 1 \\ 2 \end{bmatrix} \in \mathbb{R}^2$$

设 V 是非空子集, P 是一数域, 向量空间 V 满足:

- 向量加法: $V + V \rightarrow V$, 记作 $\forall x, y \in V$, 则 $x + y \in V$ (加法封闭)
- 标量乘法: $F \times V \rightarrow V$, 记作 $\forall x \in V, \lambda \in P$, 则 $\lambda x \in V$ (乘法封闭)

上述两个运算满足下列八条规则($\forall x, y, z \in V, \lambda, \mu \in P$)

- $x + y = y + x$ (交换律)
- $x + (y + z) = (x + y) + z$ (结合律)
- V 存在一个零元素, 记作 0 , $x + 0 = x$
- 存在 x 的负元素, 记作 $-x$, 满足 $x + (-x) = 0$
- $\forall x \in V$, 都有 $1x = x, 1 \in P$
- $\lambda(\mu x) = (\lambda\mu)x$
- $(\lambda + \mu)x = \lambda x + \mu x$
- $\lambda(x + y) = \lambda x + \lambda y$

向量空间也称为线性空间。 \mathbb{R}^n

如果 $x, y \in \mathbb{R}^2$, 则 $x + y \in \mathbb{R}^2$, $\lambda x \in \mathbb{R}^2$ ($\lambda \in \mathbb{R}$)

1.4 内积

■ 定义：在数域 \mathbb{R} 上的向量空间 V 定义函数 $\langle \cdot, \cdot \rangle: V \times V \rightarrow \mathbb{R}$, 满足：

- ① $\langle a, a \rangle \geq 0, \forall a \in V$, 当且仅当 $a=0$ 时 $\langle a, a \rangle=0$;
- ② $\langle \alpha a + \beta b, c \rangle = \alpha \langle a, c \rangle + \beta \langle b, c \rangle, \forall \alpha, \beta \in \mathbb{R}$, 且 $a, b, c \in V$;
- ③ $\langle a, b \rangle = \langle b, a \rangle, \forall a, b \in V$;

则函数 $\langle \cdot, \cdot \rangle$ 称为内积。

■ 例子：在向量空间 \mathbb{R}^n 上，计算两个向量对应项相乘之后求和函数：

$$\langle a, b \rangle = a_1 b_1 + a_2 b_2 + \dots + a_n b_n = a^T b$$

$$a = \begin{bmatrix} a_1 \\ a_2 \\ \vdots \\ a_n \end{bmatrix}, b = \begin{bmatrix} b_1 \\ b_2 \\ \vdots \\ b_n \end{bmatrix} \in \mathbb{R}^n$$

1.4.1 内积的性质

- 交换律： $a^T b = b^T a$
- 结合律： $(\gamma a)^T b = \gamma(a^T b)$
- 分配律： $(a + b)^T c = a^T c + b^T c$
- 例如：

$$(a + b)^T (c + d) = a^T c + a^T d + b^T c + b^T d$$

1.4.2 常用的内积等式

- 选出第 i 项： $e_i^T a = a_i$
- 向量每一项之和： $\mathbf{1}^T a = a_1 + \dots + a_n$
- 向量每一项的平方和： $a^T a = a_1^2 + \dots + a_n^2$

$$a = \begin{bmatrix} a_1 \\ a_2 \\ \vdots \\ a_n \end{bmatrix}, e_i = \begin{bmatrix} 0 \\ \vdots \\ 1 \\ \vdots \\ 0 \end{bmatrix} \in \mathbb{R}^n$$

第 i 项为1, 其它为0

1.4.3 柯西—施瓦茨Cauchy-Schwartz不等式

设 $\langle \cdot, \cdot \rangle$ 是向量空间 V 上的内积, $\forall x, y \in V$, 则有

$$|\langle x, y \rangle|^2 \leq \langle x, x \rangle \langle y, y \rangle$$

当 $x = \beta y$, $\beta \in \mathbb{R}$ 等式成立。

证明：令 $\lambda \in \mathbb{R}$, 则有

$$\begin{aligned} 0 &\leq \langle x + \lambda y, x + \lambda y \rangle \\ &= \langle x, x \rangle + \lambda \langle y, x \rangle + \lambda \langle x, y \rangle + \lambda^2 \langle y, y \rangle \\ &= \langle x, x \rangle + 2\lambda \langle y, x \rangle + \lambda^2 \langle y, y \rangle \end{aligned}$$

则有 $\lambda^2 \langle y, y \rangle + 2\lambda \langle y, x \rangle + \langle x, x \rangle \geq 0, \forall \lambda \in \mathbb{R}$.

$$\Delta = (2\langle y, x \rangle)^2 - 4\langle y, y \rangle \langle x, x \rangle \leq 0$$

$$|\langle x, y \rangle|^2 \leq \langle x, x \rangle \langle y, y \rangle$$

当 $|\langle x, y \rangle|^2 = \langle x, x \rangle \langle y, y \rangle$ 时, 即有 $\langle x, x \rangle + 2\lambda \langle y, x \rangle + \lambda^2 \langle y, y \rangle = 0$,

也即 $\langle x + \lambda y, x + \lambda y \rangle = 0$, 因此 $x + \lambda y = 0$, 即 $x = -\lambda y$.

1.4.3 利润最大化：向量化表示

令 $x = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}, a = \begin{bmatrix} 40 \\ 50 \end{bmatrix}, b = \begin{bmatrix} 1 \\ 2 \end{bmatrix}, c = \begin{bmatrix} 4 \\ 3 \end{bmatrix} x \in \mathbb{R}^2$.

$$\begin{array}{ll} \max_{x_1, x_2} 40x_1 + 50x_2 & \max_x a^T x \\ s.t. x_1 + 2x_2 \leq 40 & s.t. b^T x \leq 40 \\ 4x_1 + 3x_2 \leq 120 & c^T x \leq 120 \\ x_1 \geq 0 & x_1 \geq 0 \\ x_2 \geq 0 & x_2 \geq 0 \end{array}$$

2.1 线性函数

- **线性函数**(linear function): $f: \mathbb{R}^n \rightarrow \mathbb{R}$. f 是一个将 n 维向量映射成数的函数。
- 线性函数 f 满足以下两个性质 ($\alpha \in \mathbb{R}, \beta \in \mathbb{R}, x, y \in \mathbb{R}^n$):
 - **齐次性**(homogeneity): $f(\alpha x) = \alpha f(x)$,
 - **叠加性**(Additivity): $f(x + y) = f(x) + f(y)$
- 一个函数如果满足这两个性质, 就称其为**线性函数**。
- 例子:
 - 求平均值: $f(x) = \frac{1}{n} \sum_{i=1}^n x_i$ 为线性函数。
 - 求最大值: $f(x) = \max\{x_1, x_2, \dots, x_n\}$ **并不是**线性函数。
因为: 令 $x = (1, -1), y = (-1, 1), \alpha = 0.5, \beta = 0.5$,
有 $f(\alpha x + \beta y) = 0 \neq \alpha f(x) + \beta f(y) = 1$
 $f(x + y) = \max\{x_1 + y_1, x_2 + y_2, \dots, x_n + y_n\} \leq \max\{x_1, x_2, \dots, x_n\} + \max\{y_1, y_2, \dots, y_n\} \leq f(x) + f(y)$

2.1.1 内积函数

- 对于 n 维向量 a , 满足以下形式的函数被称为**内积函数**(inner product function):



$$f(x) = a^T x = a_1 x_1 + a_2 x_2 + \dots + a_n x_n$$

- 上述 $f(x)$ 可以看作是每项 x_i 的加权之和。
- 内积函数都是线性的:

$$\begin{aligned} f(\alpha x + \beta y) &= a^T (\alpha x + \beta y) \\ &= a^T (\alpha x) + a^T (\beta y) \\ &= \alpha (a^T x) + \beta (a^T y) \\ &= \alpha f(x) + \beta f(y) \end{aligned}$$

2.1.3 仿射函数

- 定义: 一个线性函数加上一个常数称为**仿射函数**(affine function)。
- 其一般形式为 $f(x) = a^T x + b$, 其中 $a \in \mathbb{R}^n, b \in \mathbb{R}$ 为标量。
- 函数 $f: \mathbb{R}^n \rightarrow \mathbb{R}$ 为**仿射函数**满足以下条件:
 - $f(\alpha x + \beta y) = \alpha f(x) + \beta f(y), \alpha + \beta = 1, \alpha, \beta \in \mathbb{R}, x, y \in \mathbb{R}^n$



2.2 梯度与偏导

- 假设 $f: \mathbb{R}^n \rightarrow \mathbb{R}$, 函数 f 在 z 点可微, 其第 i 个分量的一阶偏导数为:

$$\begin{aligned}\frac{\partial f}{\partial z_i}(z) &= \lim_{t \rightarrow 0} \frac{f(z_1, \dots, z_{i-1}, z_i + t, z_{i+1}, \dots, z_n) - f(z)}{t} \\ &= \lim_{t \rightarrow 0} \frac{f(z + te_i) - f(z)}{t}\end{aligned}$$

- f 在点 z 的梯度为:

$$\nabla f(z) = \begin{bmatrix} \frac{\partial f}{\partial z_1}(z) \\ \vdots \\ \frac{\partial f}{\partial z_n}(z) \end{bmatrix}$$

2.2 泰勒公式

- **泰勒(近似)公式**: 一个用函数在某点的信息描述其附近取值的公式。

- 假设 $f: \mathbb{R}^n \rightarrow \mathbb{R}$, 函数 f 在 z 点充分光滑, 即处处可导。

- 函数 $f(x)$ 在 z 处作泰勒(Taylor)展开:

$$\begin{aligned}f(x) &= f(z) + \frac{\partial f}{\partial x_1}(z)(x_1 - z_1) + \frac{\partial f}{\partial x_2}(z)(x_2 - z_2) + \dots + \frac{\partial f}{\partial x_n}(z)(x_n - z_n) \\ &\quad + \frac{1}{2!} \sum_{j=1}^n \sum_{i=1}^n \frac{\partial^2 f}{\partial x_i \partial x_j}(z)(x_i - z_i)(x_j - z_j) + \dots\end{aligned}$$

↑
二阶偏导

2.2 一阶泰勒近似

- 假设 $f: \mathbb{R}^n \rightarrow \mathbb{R}$, 函数 f 在 z 点可导, 其附近的一阶泰勒公式为:

$$\hat{f}(x) = f(z) + \frac{\partial f}{\partial x_1}(z)(x_1 - z_1) + \dots + \frac{\partial f}{\partial x_n}(z)(x_n - z_n)$$

- 当 x 非常接近 z 时, $\hat{f}(x)$ 也非常接近 $f(z)$ 。

- $\hat{f}(x)$ 是关于 x 的一个仿射函数。

- 写成内积形式:

$$\hat{f}(x) = f(z) + \nabla f(z)^T (x - z) \quad \nabla f(z) = \begin{bmatrix} \frac{\partial f}{\partial x_1}(z) \\ \vdots \\ \frac{\partial f}{\partial x_n}(z) \end{bmatrix}$$

2.3 回归模型

- **回归模型(regression model)** 为(关于 x 的)仿射函数:

$$\hat{y} = x^T \beta + v$$

- x 是特征向量(feature vector); 它的元素 x_i 称为回归元(regressors)。

- n 维向量 β 是权重向量(weight vector)。

- 标量 v 是偏移量(offset)。 问题: 如何建立模型求解权重系数 β 和偏移量 v ?

- 标量 \hat{y} 是预测值(prediction)。

(表示某个实际结果或因变量, 用 y 表示)

3.1 范数

- **向量范数**(vector norm): 在向量空间中存在一个函数 $\|\cdot\|: \mathbb{R}^n \rightarrow \mathbb{R}$, 且满足以下条件:

- **齐次性**: $\|\alpha x\| = |\alpha| \|x\|$, $\alpha \in \mathbb{R}$ 且 $x \in \mathbb{R}^n$;
 - **三角不等式**: $\|x + y\| \leq \|x\| + \|y\|$, $x, y \in \mathbb{R}^n$;
 - **非负性**: $\|x\| \geq 0$, $x \in \mathbb{R}^n$ 且 $\|x\| = 0 \Leftrightarrow x = 0$;
- 则称 $\|\cdot\|$ 为向量范数。

- 例子: 向量空间 \mathbb{R}^n 有许多范数:

- ℓ_1 -范数 (曼哈顿范数, Manhattan norm):

$$\|x\|_1 = |x_1| + |x_2| + \dots + |x_n|, x \in \mathbb{R}^n, \alpha \in \mathbb{R}.$$

$$\|\alpha x\|_1 = |\alpha x_1| + |\alpha x_2| + \dots + |\alpha x_n| = |\alpha| \|x\|_1 \geq 0$$

$$\|x + y\|_1 = |x_1 + y_1| + \dots + |x_n + y_n| \leq |x_1| + |y_1| + \dots + |x_n| + |y_n| = \|x\|_1 + \|y\|_1$$

3.1 范数

- 向量空间 \mathbb{R}^n 常用的范数:

- ℓ_2 -范数 (欧几里得范数, Euclidean norm):

$$\|x\|_2 = \sqrt{(x_1^2 + x_2^2 + \dots + x_n^2)} = \sqrt{x^T x} = (\langle x, x \rangle)^{\frac{1}{2}}$$

柯西—施瓦茨不等式

$$|\langle x, y \rangle|^2 \leq \langle x, x \rangle \langle y, y \rangle = \|x\|_2^2 \|y\|_2^2$$

$$\|\alpha x\|_2 = (\langle \alpha x, \alpha x \rangle)^{\frac{1}{2}} = |\alpha| (\langle x, x \rangle)^{\frac{1}{2}} = |\alpha| \|x\|_2$$

$$\begin{aligned} \|x + y\|_2^2 &= \langle x + y, x + y \rangle = \langle x, x \rangle + \langle x, y \rangle + \langle y, x \rangle + \langle y, y \rangle \\ &= \|x\|_2^2 + 2\langle x, y \rangle + \|y\|_2^2 \leq \|x\|_2^2 + 2\|x\|_2 \|y\|_2 + \|y\|_2^2 = (\|x\|_2 + \|y\|_2)^2 \end{aligned}$$

$$\|x + y\|_2 \leq \|x\|_2 + \|y\|_2$$

3.1 范数

- 向量空间 \mathbb{R}^n 常用的范数:

- ℓ_p -范数, $p \geq 1$:

$$\|x\|_p = (|x_1|^p + |x_2|^p + \dots + |x_n|^p)^{\frac{1}{p}}, x \in \mathbb{R}^n$$

- ℓ_1 -范数 $\|x\|_1$, ℓ_2 -范数 $\|x\|_2$ 是 ℓ_p -范数的特例。

- Minkowski不等式:

$$\left(\sum_{i=1}^n |x_i + y_i|^p \right)^{\frac{1}{p}} \leq \left(\sum_{i=1}^n |x_i|^p \right)^{\frac{1}{p}} + \left(\sum_{i=1}^n |y_i|^p \right)^{\frac{1}{p}}, p \geq 1, x, y \in \mathbb{R}^n$$

- Hölder不等式:


$$\sum_{i=1}^n |x_i y_i| \leq \left(\sum_{i=1}^n |x_i|^p \right)^{\frac{1}{p}} \left(\sum_{i=1}^n |y_i|^q \right)^{\frac{1}{q}}, \frac{1}{p} + \frac{1}{q} = 1, 1 < p, q < \infty.$$

3.1 范数

- 向量空间 \mathbb{R}^n 常用的范数:

- ℓ_∞ -范数:

$$\|x\|_\infty = \max_{1 \leq i \leq n} |x_i|, x \in \mathbb{R}^n$$



$$\begin{aligned} \max_{1 \leq i \leq n} |x_i| &\leq (|x_1|^p + \dots + |x_i|^p + \dots + |x_n|^p)^{\frac{1}{p}} \leq (n \max_{1 \leq i \leq n} |x_i|^p)^{\frac{1}{p}} \\ &= n^{\frac{1}{p}} \max_{1 \leq i \leq n} |x_i| \rightarrow \max_{1 \leq i \leq n} |x_i| \quad (p \rightarrow \infty) \end{aligned}$$

- ℓ_∞ -范数是 ℓ_p -范数的特例, $p \rightarrow \infty, \|x\|_p \rightarrow \|x\|_\infty$

3.1.1 均方根

- 向量 $x \in \mathbb{R}^n$ 的均方值(mean-square value)为:

$$\frac{x_1^2 + x_2^2 + \dots + x_n^2}{n} = \frac{\|x\|_2^2}{n}$$

- n维向量 x 的均方根(root-mean-square value, RMS)为:

$$rms(x) = \sqrt{\frac{x_1^2 + x_2^2 + \dots + x_n^2}{n}} = \frac{\|x\|_2}{\sqrt{n}}$$

- $rms(x)$ 给出了 $|x_i|$ 的“典型”(typical)值。
- 例如, $rms(\mathbf{1}) = 1$ (与 n 无关)。
- 均方根(RMS)值对于比较不同长度的向量大小是比较有用的。

3.1.2 切比雪夫不等式

- 假设 k 为向量 x 分量满足条件 $|x_i| \geq a$ 的个数, 即 $x_i^2 \geq a^2$ 的个数。
- 因此: $\|x\|_2^2 = x_1^2 + x_2^2 + \dots + x_n^2 \geq ka^2$
- 将 a^2 移项, 可得到 $k \leq \frac{\|x\|_2^2}{a^2}$
- 满足 $|x_i| \geq a$ 的 x_i 数量不会超过 $\frac{\|x\|_2^2}{a^2}$
- 以上就是切比雪夫不等式。
- 使用均方根(RMS)来描述: $rms(x) = \sqrt{\frac{x_1^2 + x_2^2 + \dots + x_n^2}{n}} = \frac{\|x\|_2}{\sqrt{n}}$
- $|x_i| \geq a$ 的项数占整体的比例不会超过 $\left(\frac{rms(x)}{a}\right)^2$, 即 $\frac{k}{n} \leq \left(\frac{rms(x)}{a}\right)^2$ 。
- 例子: 不会超过4%的项能满足 $|x_i| \geq 5 * rms(x)$ 。

3.3 标准差

- 定义: 标准差是算术平均值的算术平方根, 通常希腊字母 σ 表示。
- 对于 n 维向量 x , 其平均值为 $avg(x) = \frac{\mathbf{1}^T x}{n}$ 。
- 去均值(de-meanned)向量为 $\tilde{x} = x - avg(x)\mathbf{1}$, 因此 $avg(\tilde{x}) = 0$ 。
- x 的标准差可以表示为:

$$std(x) = rms(\tilde{x}) = \frac{\|x - (\mathbf{1}^T x / n)\mathbf{1}\|_2}{\sqrt{n}}$$

- $std(x)$ 表示数据元素的变化程度。
- 对于常数 α , 当且仅当 $x = \alpha\mathbf{1}$ 时, $std(x) = 0$ 。
- 一个基本公式:


$$rms(x)^2 = avg(x)^2 + std(x)^2$$

课后作业

3.4 角

- 两个非零向量 a 和 b 之间的角(angle)定义为如下形式:

$$\angle(a, b) = \arccos\left(\frac{a^T b}{\|a\|_2 \|b\|_2}\right)$$



- $\angle(a, b)$ 的取值范围为 $[0, \pi]$, 且满足:

$$a^T b = \|a\|_2 \|b\|_2 \cos(\angle(a, b))$$

- 在二维和三维向量之中, 这里的角与普通角度(ordinary angle)是一致的。

3.4.1 角的分类

$$\theta = \angle(a, b)$$


■ $\theta = \pi/2 = 90^\circ$: a 和 b 为正交, 写作 $a \perp b$ ($a^T b = 0$)。

■ $\theta = 0$: a 和 b 为同向的 ($a^T b = \|a\| \|b\|$)。

■ $\theta = \pi = 180^\circ$: a 和 b 为反向的 ($a^T b = -\|a\| \|b\|$)。


■ $\theta < \pi/2 = 90^\circ$: a 和 b 成锐角 ($a^T b > 0$)。

■ $\theta > \pi/2 = 90^\circ$: a 和 b 成钝角 ($a^T b < 0$)。



3.4.1 球面距离

■ 如果 a, b 都在半径为 R 的球面上, 沿球面的距离为 $R\angle(a, b)$ 。



3.4.2 相关系数

■ 给定向量 a 和 b , 其去均值向量为:

$$\tilde{a} = a - \text{avg}(a)1, \quad \tilde{b} = b - \text{avg}(b)1$$

■ 在 $\tilde{a} \neq 0$ 和 $\tilde{b} \neq 0$ 下, a 和 b 的相关系数为:

$$\rho = \frac{\tilde{a}^T \tilde{b}}{\|\tilde{a}\|_2 \|\tilde{b}\|_2}$$

■ $\rho = \cos \angle(\tilde{a}, \tilde{b})$:

- $\rho = 0$: a 和 b 是不相关的。
- $\rho > 0.8$ (左右): a 和 b 高度正相关。
- $\rho < -0.8$ (左右): a 和 b 高度负相关。

■ 高度相关指的是 a_i 和 b_i 通常都在它们两者的平均值之上(之下)。

4.1 渐近记号 — o 记号

高阶无穷小记号 o (小 o 记号)

设 x, y 是同一变化过程中的无穷小, 即 $x \rightarrow 0, y \rightarrow 0$, 如果它们极限

$$\lim \frac{y}{x} = 0$$

则称 y 是 x 的高阶无穷小, 记作 $y = o(x)$ 。同时存在常数 C , 满足

$$\lim \frac{y}{Cx} = \frac{1}{C} \lim \frac{y}{x} = 0$$

也即则称 y 是 Cx 的高阶无穷小, 记作 $y = o(Cx)$ 。

4.1 必要条件

■ 定理1.1 假设函数 f 在 \hat{x} 可微, 则有

$$\hat{x} = \operatorname{argmin}_{x \in \mathbb{R}^n} f(x) \Rightarrow \nabla f(\hat{x}) = 0.$$

证明: 函数 f 在 \hat{x} 一阶泰勒展开, 则有

$$f(x) = f(\hat{x}) + \langle \nabla f(\hat{x}), x - \hat{x} \rangle + o(\|x - \hat{x}\|_2).$$

假设 $\nabla f(\hat{x}) \neq 0$, 则令 $\tilde{x} = \hat{x} - t \nabla f(\hat{x}), t > 0$, 可得

$$f(\tilde{x}) = f(\hat{x}) - t \|\nabla f(\hat{x})\|_2^2 + o(t \|\nabla f(\hat{x})\|_2).$$

当 $t \rightarrow 0$, 则 $t \|\nabla f(\hat{x})\|_2 \rightarrow 0$, 高阶无穷小 $o(t \|\nabla f(\hat{x})\|_2) \rightarrow 0$

当 t 足够小时, 存在 $t \|\nabla f(\hat{x})\|_2 > o(t \|\nabla f(\hat{x})\|_2)$, 即

$$-t \|\nabla f(\hat{x})\|_2^2 + o(t \|\nabla f(\hat{x})\|_2) < 0$$

$$f(\tilde{x}) = f(\hat{x}) - t \|\nabla f(\hat{x})\|_2^2 + o(t \|\nabla f(\hat{x})\|_2) < f(\hat{x}).$$


与 $\hat{x} = \operatorname{argmin}_{\mathbb{R}^n} f(x)$ 矛盾。

4.2 凸集

凸集的定义

定义域 $\Omega \in \mathbb{R}^n$ 称为凸的(Convex)集合, 则 $\forall x, y \in \Omega, \alpha \in \mathbb{R}, 0 \leq \alpha \leq 1$, 有

$$\alpha x + (1 - \alpha)y \in \Omega$$




4.2 凸函数

凸函数

设函数 $f(x)$ 定义于称为凸的定义域 $\Omega \in \mathbb{R}^n$, 当称其为凸函数时,

对于 $\forall x, y \in \Omega, \alpha \in \mathbb{R}, 0 \leq \alpha \leq 1$, 满足:

$$f(\alpha x + (1 - \alpha)y) \leq \alpha f(x) + (1 - \alpha)f(y),$$



4.2 凸函数

例子1: $f(x) = x^2, x \in \mathbb{R}.$ $\forall x, y \in \Omega, \alpha \in \mathbb{R}, 0 \leq \alpha \leq 1$

$$\begin{aligned} f(\alpha x + (1 - \alpha)y) &= (\alpha x + (1 - \alpha)y)^2 \\ &= \alpha^2 x^2 + 2\alpha(1 - \alpha)xy + (1 - \alpha)^2 y^2 \\ &= \alpha x^2 + (1 - \alpha)y^2 + \alpha(1 - \alpha)(x - y)^2 + 2\alpha(1 - \alpha)xy \\ &= \alpha x^2 + (1 - \alpha)y^2 - \alpha(1 - \alpha)(x - y)^2 + 2\alpha(1 - \alpha)xy \\ &\leq \alpha x^2 + (1 - \alpha)y^2 = \alpha f(x) + (1 - \alpha)f(y) \end{aligned}$$

例子2: $f(x) = \|x\|$, 其中 $\|\cdot\|$ 表示 \mathbb{R}^n 上的向量范数, $x \in \mathbb{R}^n$.

$$\|\alpha x + (1 - \alpha)y\| \leq \|\alpha x\| + \|(1 - \alpha)y\| = |\alpha| \|x\| + |1 - \alpha| \|y\|$$

例子3: $f(x) = \|x\|_2^2, x \in \mathbb{R}^n$? 作业

4.2 凸函数

引理：可微函数 f 是凸函数的充要条件：

$$f(y) \geq f(x) + \langle \nabla f(x), y - x \rangle, \quad \forall x, y.$$

证明：首先，证明一维情况 $f: \mathbb{R} \rightarrow \mathbb{R}, \alpha \in [0, 1]$.

“ \Rightarrow ”充分条件： $f(\alpha x + (1 - \alpha)y) = f(x + (1 - \alpha)(y - x))$

$\leq \alpha f(x) + (1 - \alpha)f(y)$ ，则有

$$f(y) \geq f(x) + \frac{f(x + (1 - \alpha)(y - x)) - f(x)}{(1 - \alpha)(y - x)}(y - x),$$

令 $\alpha \rightarrow 1 -$ ，则有 $(1 - \alpha)(y - x) \rightarrow 0$ ，即 $f(y) \geq f(x) + f'(x)(y - x)$.

“ \Leftarrow ”必要条件：令 $y \neq x, z = \alpha x + (1 - \alpha)y$ ，则有

$$f(x) \geq f(z) + f'(z)(x - z), f(y) \geq f(z) + f'(z)(y - z).$$

$$\text{可得 } \alpha f(x) + (1 - \alpha)f(y) \geq f(z) + \alpha f'(z)(x - z) + (1 - \alpha)f'(z)(y - z)$$

$$= f(z) + f'(z)(\alpha x + (1 - \alpha)y - z) = f(z)$$

证明 n 维情况 $f: \mathbb{R}^n \rightarrow \mathbb{R}$.

“ \Rightarrow ”充分条件：令 $g(t) = f(tx + (1 - t)y), t \in \mathbb{R}$ ，则 $g'(t) = \langle \nabla f(tx + (1 - t)y), x - y \rangle$

由于 f 是凸函数，证明 $g(t)$ 也是凸函数；并可得 $g(0) \geq g(1) + g'(1)(-1)$ ，得证

“ \Leftarrow ”必要条件：与一维类似。 课后作业

4.2 凸函数

定理：如果可微函数 f 是凸函数，则有

$$\hat{x} = \arg \min_{x \in \mathbb{R}^n} f(x) \Leftrightarrow \nabla f(\hat{x}) = 0.$$

证明：已证 $\hat{x} = \arg \min_{x \in \mathbb{R}^n} f(x) \Rightarrow$ 可得 $\nabla f(\hat{x}) = 0$.

只需证 $\nabla f(\hat{x}) = 0 \Rightarrow \hat{x} = \arg \min_{x \in \mathbb{R}^n} f(x)$.

由于函数 f 是可微凸的，则有 $\forall x \in \mathbb{R}^n$,

$$f(x) \geq f(\hat{x}) + \langle \nabla f(\hat{x}), x - \hat{x} \rangle \\ \geq f(\hat{x}) + \langle 0, x - \hat{x} \rangle = f(\hat{x})$$

可得 $f(x) \geq f(\hat{x}), \hat{x} = \arg \min_{x \in \mathbb{R}^n} f(x)$.

4.3 优化问题：向量偏导

■ 假设向量 $x, z \in \mathbb{R}^n$:


$$x = \begin{bmatrix} x_1 \\ \vdots \\ x_n \end{bmatrix}, z = \begin{bmatrix} z_1 \\ \vdots \\ z_n \end{bmatrix}$$

$$f(z) = x^T z + z^T z = \sum_{i=1}^n \{x_i z_i + z_i^2\}$$

$$\nabla f(z) = \begin{bmatrix} \frac{\partial f(z)}{\partial z_1} \\ \vdots \\ \frac{\partial f(z)}{\partial z_n} \end{bmatrix} = \begin{bmatrix} x_1 + 2z_1 \\ \vdots \\ x_n + 2z_n \end{bmatrix} = x + 2z$$

4.3 优化问题：标量

■ 假设 $a, b \in \mathbb{R}^n, a \neq 0, t \in \mathbb{R}$ ，当 t 多大时， ta 到 b 之间的距离最小：



$$f(t) = \|ta - b\|_2^2 = \langle ta - b, ta - b \rangle = t^2 a^T a - 2ta^T b + b^T b$$

$$\nabla f(t) = 2ta^T a - 2a^T b = 0$$

$$t = \frac{a^T b}{a^T a} = \frac{a^T b}{\|a\|_2^2}$$

4.4 k-means算法

■ K-means算法是将N个向量 $x_i \in \mathbb{R}^n$ 划分成k类的迭代聚类算法。

■ 聚类目标找到向量 x_i 的“标签 c_i ”和“聚类中心 z_j ”。

$$c_i = \operatorname{argmin}_{j=\{1,\dots,k\}} \|x_i - z_j\|_2^2, i = 1, 2, \dots, N.$$
$$\min_{z_j} \sum_{i \in G_j} \|x_i - z_j\|_2^2, j = 1, \dots, k.$$

■ 步骤:

- 1、在N个点中随机选取k个点，分别作为聚类中心 z_j ;
- 2、更新聚类标签 c_i : 计算每个点 x_i 到k个聚类中心的距离，并将其分配到最近的聚类中心所在的聚类中;
- 3、更新聚类中心 z_j : 重新计算每个聚类现在的质心，并以其作为新的聚类中心;
- 4、重复步骤2、3，直到所有聚类中心不再变化。

4.4 k-means算法

■ 聚类目标找到N个向量 $x_i \in \mathbb{R}^n$ 的“标签 c_i ”和“聚类中心 z_j ”。

■ K-means算法划分成k类步骤:

- 1、在N个点中随机选取k个点作为聚类中心 z_j ;
- 2、更新聚类标签 c_i : 计算每个点 x_i 到k个聚类中心 z_j 的距离，并将其分配到最近的聚类中心 z_j 所在的聚类中 $c_i = j$;
 $\|x_i - z_j\|_2^2 = \operatorname{argmin}\{\|x_i - z_1\|_2^2, \|x_i - z_2\|_2^2, \dots, \|x_i - z_k\|_2^2\}$


$$c_i = j$$

- 3、更新聚类中心 z_j : 根据更新标签 c_i ，更新属于第j类下标集合

$$G_j = \{i: c_i = j\}, \text{ 重新计算 } c_i \text{ 类的聚类中心 } z_j;$$
$$z_j = \frac{1}{|G_j|} \sum_{i \in G_j} x_i$$

- 4、重复步骤2、3，直到所有聚类中心不再变化。

5.1 线性相关

■ 定义: 对于向量 $a_1, \dots, a_m \in \mathbb{R}^n$ ，如果存在不全为零的数 $\beta_1, \dots, \beta_m \in \mathbb{R}$ ，使得

$$\beta_1 a_1 + \dots + \beta_m a_m = 0$$

则称向量 a_1, \dots, a_m 是线性相关(linearly dependent)。

■ 等价于: 至少有一个向量 a_i 是其它向量的线性组合。

■ 向量集 $\{a_1\}$ 是线性相关的，当且仅当 $a_1 = 0$ 。

■ 向量集 $\{a_1, a_2\}$ 是线性相关的，当且仅当其中一个 $a_1 = \beta a_2, \beta \neq 0$ 。

■ 对于两个以上的向量，则需要用定义去描述。

5.2 线性无关

■ 定义: 如果n维向量集 $\{a_1, \dots, a_m\}$ 不是线性相关的，即线性独立(linearly independent)，也称线性无关，即:

$$\beta_1 a_1 + \dots + \beta_m a_m = 0$$

当且仅当 $\beta_1 = \dots = \beta_m = 0$ ，上述等式成立。

■ 等价于: 不存在一个向量 a_i 是其它向量的线性组合。

■ 注: 一个n维向量集最多有n个线性无关的向量，也就是说如果n维向量集有n+1个向量，那它们必线性相关，P.94。

■ 例子: n维单位向量 e_1, \dots, e_n 是线性独立的。

$$e_i = \begin{bmatrix} 0 \\ \vdots \\ 1 \\ \vdots \\ 0 \end{bmatrix} \in \mathbb{R}^n \text{ 第 } i \text{ 项为 } 1, \text{ 其它为 } 0.$$

5.2.1 线性无关向量的线性组合

- 假设 x 是线性无关向量 a_1, \dots, a_k 的线性组合:

$$x = \beta_1 a_1 + \dots + \beta_k a_k$$

则其系数 β_1, \dots, β_k 是唯一的, 即如果有:

$$x = \gamma_1 a_1 + \dots + \gamma_k a_k$$

则对于 $i = 1, \dots, k$, 有 $\beta_i = \gamma_i$ 。

- 系数是唯一的原因:

$$x - x = (\beta_1 - \gamma_1)a_1 + \dots + (\beta_k - \gamma_k)a_k = 0$$

由于向量 a_1, \dots, a_k 线性无关, 有 $\beta_1 - \gamma_1 = \dots = \beta_k - \gamma_k = 0$ 。

5.3 基

- 定义: n 个线性独立的 n 维向量 a_1, \dots, a_n 的集合称为**基(basis)**

- 任何一个 **n 维向量 b** 都可以用它们的线性组合来表示:

$$b = \beta_1 a_1 + \dots + \beta_n a_n$$

- 同一向量的系数 β_1, \dots, β_n 是唯一的
- 上述等式称为向量 b 在基底 a_1, \dots, a_n 下的分解

- 例子: e_1, \dots, e_n 是一组基, 那么 b 在此基底下的分解为:

$$b = b_1 e_1 + \dots + b_n e_n \quad b = \begin{bmatrix} b_1 \\ \vdots \\ b_n \end{bmatrix} \in \mathbb{R}^n$$

5.4 标准正交向量

- 定义: 在 **n 维向量集** a_1, \dots, a_k 中, 如果对于 $i \neq j$, 都有 $a_i \perp a_j$, 则称它们相互**正交(orthogonal)**。
- 如果 n 维向量集 a_1, \dots, a_k 相互正交, 且每个向量的模长都为单位长度1, 即对于 $i = 1, \dots, k$, 有 $\|a_i\|_2^2 = 1$, 则称它们是**标准正交(orthonormal)**的。
- 标准正交向量用内积表示为:

$$a_i^T a_j = \begin{cases} 1 & i = j \\ 0 & i \neq j \end{cases}$$


- 标准正交的向量集是线性无关的。
- 根据**线性无关**的性质, 必有向量集向量个数 $k \leq n$, P.94。
- 当 $k = n$ 时, a_1, \dots, a_n 是 n 维向量的一个标准正交基。

5.4.2 标准正交分解

- 如果 a_1, \dots, a_n 是一个标准正交基, 对于任意 n 维向量 x :

$$x = (a_1^T x) a_1 + \dots + (a_n^T x) a_n$$

则称其为 x 在标准正交基下的标准正交分解。



- 为了验证以上公式, 可以让等式两边同时乘以任意 a_i :

$$a_i^T x = (a_1^T x) a_1^T a_1 + \dots + (a_i^T x) \mathbf{a_i^T a_i} + \dots + (a_n^T x) a_n^T a_n = a_i^T x$$

5.5 Gram-Schmidt(正交化)算法

- 给定n维向量 a_1, \dots, a_k , 如何将其标准正交化?
- Gram-Schmidt(正交化)算法常用于解决上述问题, 且能检验 a_1, \dots, a_k 是否是线性相关。
- 步骤 ($i = 2, \dots, k$) : $q_1 = a_1 / \|a_1\|_2$
 - 1、正交化: $\tilde{q}_i = a_i - (q_1^T a_i)q_1 - \dots - (q_{i-1}^T a_i)q_{i-1}$;
 - 2、检验线性相关: 如果 $\tilde{q}_i = 0$, 提前退出迭代;
 - 3、单位化: $q_i = \tilde{q}_i / \|\tilde{q}_i\|_2$ 。
- 如果步骤2中未提前结束迭代, 那么 a_1, \dots, a_k 是线性独立的, 而且 q_1, \dots, q_k 是标准正交基。
- 如果在第j次迭代中提前结束, 说明 a_j 是 a_1, \dots, a_{j-1} 的线性组合, 因此 a_1, \dots, a_k 是线性相关的。

5.5.1 算法分析

归纳法来证明 q_1, \dots, q_{i-1}, q_i 是标准正交的:

- 假设第 $i-1$ 次迭代成立, 即: $q_r \perp q_s, \forall r, s < i$.
- 正交化步骤保证有以下关系成立:
 - $\tilde{q}_i = a_i - (q_1^T a_i)q_1 - \dots - (q_{i-1}^T a_i)q_{i-1}$;
- 等式两边同时乘以 $q_j^T, j = 1, \dots, i-1$:
$$q_j^T \tilde{q}_i = q_j^T a_i - (q_1^T a_i)(q_j^T q_1) - \dots - (q_{i-1}^T a_i)(q_j^T q_{i-1})$$
$$= q_j^T a_i - q_j^T a_i = 0 \quad \because q_j^T q_r = 0, j \neq r, q_j^T q_j = 1.$$
- 因此 $\tilde{q}_i \perp q_1, \dots, \tilde{q}_i \perp q_{i-1}$ 。
- 单位化步骤保证了 $q_i = \tilde{q}_i / \|\tilde{q}_i\|_2$, 即 q_1, \dots, q_i 是标准正交。

5.5.1 算法分析

假设Schmidt正交法未在第i次迭代提前终止:

- $\tilde{q}_i = a_i - (q_1^T a_i)q_1 - \dots - (q_{i-1}^T a_i)q_{i-1}$;
- a_i 是 q_1, \dots, q_i 的一个线性组合: $q_i = \tilde{q}_i / \|\tilde{q}_i\|_2$
$$a_i = \|\tilde{q}_i\|_2 q_i + (q_1^T a_i)q_1 + \dots + (q_{i-1}^T a_i)q_{i-1}$$
- 则有 $q_i = (1/\|\tilde{q}_i\|_2)(a_i - (q_1^T a_i)q_1 - \dots - (q_{i-1}^T a_i)q_{i-1})$
- 归纳假设, 每个 q_{i-1} 都是 a_1, \dots, a_{i-1} 的线性组合:
$$q_2 = (1/\|\tilde{q}_2\|_2)(a_2 - (q_1^T a_2)q_1)$$
$$= (1/\|\tilde{q}_2\|_2)(a_2 - (q_1^T a_2)a_1/\|a_1\|_2)$$
$$q_3 = (1/\|\tilde{q}_3\|_2)(a_3 - (q_1^T a_3)q_1 - (q_2^T a_3)q_2)$$

课后
作业
- 通过对i的归纳证明, 可得 q_i 是 a_1, \dots, a_i 的一个线性组合。

5.5.1 算法分析

假设Schmidt正交法在第j次迭代提前终止:

- a_j 是 q_1, \dots, q_{j-1} 的一个线性组合:
$$a_j = (q_1^T a_j)q_1 + \dots + (q_{j-1}^T a_j)q_{j-1}$$
- 每一个 q_1, \dots, q_{j-1} 都是 a_1, \dots, a_{j-1} 的线性组合。
- 因此 a_j 是 a_1, \dots, a_{j-1} 的线性组合。

5.5.2 例子

- 给定三个向量，使用Schmidt正交法来正交化：

$$a_1 = (-1, 1, -1, 1), \quad a_2 = (-1, 3, -1, 3), \quad a_3 = (1, 3, 5, 7)$$

- $i = 1$: $\tilde{q}_1 = a_1, \|\tilde{q}_1\|_2 = 2$, 单位化:

$$q_1 = \frac{1}{\|\tilde{q}_1\|_2} \tilde{q}_1 = \left(-\frac{1}{2}, \frac{1}{2}, -\frac{1}{2}, \frac{1}{2}\right)$$

- $i = 2$: $q_1^T a_2 = 4$, 正交化:

$$\tilde{q}_2 = a_2 - (q_1^T a_2)q_1 = \begin{bmatrix} -1 \\ 3 \\ -1 \\ 3 \end{bmatrix} - 4 \begin{bmatrix} -1/2 \\ 1/2 \\ -1/2 \\ 1/2 \end{bmatrix} = \begin{bmatrix} 1 \\ 1 \\ 1 \\ 1 \end{bmatrix}$$

5.5.2 例子

- $i = 2$: $\|\tilde{q}_2\| = 2$, 单位化:

$$q_2 = \frac{1}{\|\tilde{q}_2\|_2} \tilde{q}_2 = \left(\frac{1}{2}, \frac{1}{2}, \frac{1}{2}, \frac{1}{2}\right)$$

- $i = 3$: $q_1^T a_3 = 2$ 和 $q_2^T a_3 = 8$, 正交化:

$$\tilde{q}_3 = a_3 - (q_1^T a_3)q_1 - (q_2^T a_3)q_2 = \begin{bmatrix} 1 \\ 3 \\ 5 \\ 7 \end{bmatrix} - 2 \begin{bmatrix} -1/2 \\ 1/2 \\ -1/2 \\ 1/2 \end{bmatrix} - 8 \begin{bmatrix} 1/2 \\ 1/2 \\ 1/2 \\ 1/2 \end{bmatrix} = \begin{bmatrix} -2 \\ -2 \\ 2 \\ 2 \end{bmatrix}$$

- $i = 3$: $\|\tilde{q}_3\|_2 = 4$, 单位化:

$$q_3 = \frac{1}{\|\tilde{q}_3\|_2} \tilde{q}_3 = \left(-\frac{1}{2}, -\frac{1}{2}, \frac{1}{2}, \frac{1}{2}\right)$$

5.5.3 时间复杂度

- 第 i 次迭代的步骤1需要进行 $i - 1$ 次内积:

$$q_1^T a_i, \dots, q_{i-1}^T a_i$$

需要进行 $(i - 1)(2n - 1)$ 次flop。

- 计算 \tilde{q}_i 需要进行 $2n(i - 1)$ 次flop。 $\tilde{q}_i = a_i - (q_1^T a_i)q_1 - \dots - (q_{i-1}^T a_i)q_{i-1}$

- 计算 $\|\tilde{q}_i\|_2$ 和 q_i 需要进行 $3n$ 次flop。

- 总共需要:

$$\sum_{i=1}^k ((4n - 1)(i - 1) + 3n) = (4n - 1) \frac{k(k - 1)}{2} + 3nk \approx 2nk^2$$

- 因此Schmidt正交法的时间复杂度为 $2nk^2$ (其中 n 为向量维数, k 为向量个数)。

6.2 矩阵形状

- 标量: 不区分一个 1×1 矩阵和一个标量

- 向量: 不区分一个 $n \times 1$ 矩阵和一个向量

- 行向量和列向量

- 一个 $1 \times n$ 矩阵被称为一个行向量

- 一个 $n \times 1$ 矩阵被称为一个列向量

- 高形, 宽形和方形矩阵, 一个大小为 $m \times n$ 的矩阵为:

- 高的, 如果 $m > n$

- 宽的, 如果 $m < n$

- 方的, 如果 $m = n$

$$\begin{bmatrix} 1 & 0 \\ 1 & 1 \\ 1 & 0 \end{bmatrix} \quad \begin{bmatrix} 1 & 0 & 0 \\ 1 & 1 & 1 \end{bmatrix} \quad \begin{bmatrix} 1 & 0 & 0 \\ 1 & 1 & 1 \\ 3 & 2 & 1 \end{bmatrix}$$

6.4 矩阵的行表示和列表示

- 矩阵 $A \in \mathbb{R}^{m \times n}$, 可通过其列向量(m-vector)进行表示,假设其列向量为 $a_1, \dots, a_n \in \mathbb{R}^m$, 则有

$$A = [a_1 \quad \dots \quad a_n]$$

- 或者通过其行向量 b_1, \dots, b_m 进行表示:

$$A = \begin{bmatrix} b_1 \\ \vdots \\ b_m \end{bmatrix}, b_i^T \in \mathbb{R}^n, i = 1, \dots, m$$

6.6 对称和Hermitian矩阵

- 对称矩阵: $A_{ij} = A_{ji}$

$$A = \begin{bmatrix} 4 & 3 & -2 \\ 3 & -1 & 5 \\ -2 & 5 & 0 \end{bmatrix}, A^T = A.$$

- Hermitian矩阵: $A_{ij} = \bar{A}_{ji}$ (共轭复数)

$$\begin{bmatrix} 4 & 3-2i & -1+i \\ 3+2i & -1 & 2i \\ -1-i & -2i & 0 \end{bmatrix}$$

6.7 对角矩阵, 三角矩阵

- 对角矩阵: 对角线上元素不全为0, 其余元素全为0

$$\begin{bmatrix} 1 & 0 & 0 \\ 0 & -2 & 0 \\ 0 & 0 & 5 \end{bmatrix}, \begin{bmatrix} 2 & 0 & 0 \\ 0 & 0 & 0 \\ 0 & 0 & 3 \end{bmatrix}$$

- 下三角矩阵: 方形矩阵且当 $i < j$ 时 $A_{ij} = 0$

$$\begin{bmatrix} 1 & 0 & 0 \\ 2 & -2 & 0 \\ 1 & 1 & 5 \end{bmatrix}, \begin{bmatrix} 1 & 0 & 0 \\ 1 & 1 & 0 \\ 1 & 1 & 5 \end{bmatrix}$$

- 上三角矩阵: 方形矩阵且当 $i > j$ 时 $A_{ij} = 0$

$$\begin{bmatrix} 1 & 1 & 1 \\ 0 & -2 & 1 \\ 0 & 0 & 5 \end{bmatrix}, \begin{bmatrix} 1 & 2 & 2 \\ 0 & 1 & 2 \\ 0 & 0 & 5 \end{bmatrix}$$

6.10 共轭转置

- 矩阵 A 的共轭转置表示为 A^H , 若 $A \in \mathbb{C}^{m \times n}$, 则 $A^H \in \mathbb{C}^{n \times m}$, 其被定义为: $(A^H)_{ij} = \bar{A}_{ji}$, $i = 1, \dots, n; j = 1, \dots, m$;
- 例如矩阵 $A \in \mathbb{C}^{m \times n}$, 则其共轭转置为一个 $n \times m$ 矩阵

$$A^H = \begin{bmatrix} \bar{A}_{11} & \bar{A}_{21} & \dots & \bar{A}_{m1} \\ \bar{A}_{12} & \bar{A}_{22} & \dots & \bar{A}_{m2} \\ \vdots & \vdots & \ddots & \vdots \\ \bar{A}_{1n} & \bar{A}_{2n} & \dots & \bar{A}_{mn} \end{bmatrix}$$

- $(A^H)^H = A$
- Hermitian矩阵满足 $A = A^H$
- $(\beta A)^H = \beta A^H, (A + B)^H = A^H + B^H$

6.11 矩阵乘法

- 定义：设矩阵 $A \in \mathbb{R}^{m \times p}$, $B \in \mathbb{R}^{p \times n}$, 那么矩阵 A 与 B 的乘积，记作 $C = AB$ ，矩阵 $C \in \mathbb{R}^{m \times n}$ 的第 i 行第 j 列元素 C_{ij}

$$C_{ij} = \sum_{k=1}^p A_{ik} B_{kj}$$

- 例子：

$$\begin{bmatrix} -1.5 & 3 & 2 \\ 1 & -1 & 0 \end{bmatrix} \begin{bmatrix} -1 & -1 \\ 0 & -2 \\ 1 & 0 \end{bmatrix} = \begin{bmatrix} 3.5 & -4.5 \\ -1 & 1 \end{bmatrix}$$

- 矩阵 A 的列大小必须等于 B 的行大小

6.12 矩阵乘法性质

- 结合律： $(AB)C = A(BC)$
- 分配律： $A(B + C) = AB + AC$
- $(AB)^T = B^T A^T$, $(AB)^H = B^H A^H$
- 一般情况下： $AB \neq BA$
- 对于方阵 A 有， $IA = AI = A$

6.13 分块矩阵乘法

- 例子：

$$\begin{bmatrix} A & B \\ C & D \end{bmatrix} \begin{bmatrix} W & Y \\ X & Z \end{bmatrix} = \begin{bmatrix} AW + BX & AY + BZ \\ CW + DX & CY + DZ \end{bmatrix}$$

6.14 矩阵-向量乘积

- 矩阵 $A \in \mathbb{R}^{m \times n}$ 和一个向量 $x \in \mathbb{R}^n$ 的积为

$$Ax = \begin{bmatrix} A_{11}x_1 + A_{12}x_2 + \cdots + A_{1n}x_n \\ A_{21}x_1 + A_{22}x_2 + \cdots + A_{2n}x_n \\ \vdots \\ A_{m1}x_1 + A_{m2}x_2 + \cdots + A_{mn}x_n \end{bmatrix}$$

- Ax 是矩阵 A 列向量的线性组合

$$Ax = [a_1 \quad a_2 \quad \cdots \quad a_n] \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix} = x_1 a_1 + \cdots + x_n a_n$$

6.15 矩阵-向量乘积函数

- 给定矩阵 $A \in \mathbb{R}^{m \times n}$, 定义函数 $f: \mathbb{R}^n \rightarrow \mathbb{R}^m$, $f(x) = Ax$
- 该函数为一个线性函数: $A(\alpha x + \beta y) = \alpha(Ax) + \beta(Ay)$
- 任意一个线性函数都可以写成矩阵-向量乘积函数的形式

$$\begin{aligned} f(x) &= f(x_1 e_1 + x_2 e_2 + \cdots + x_n e_n) \\ &= x_1 f(e_1) + x_2 f(e_2) + \cdots + x_n f(e_n) \\ &= [f(e_1) \quad \cdots \quad f(e_n)] \begin{bmatrix} x_1 \\ \vdots \\ x_n \end{bmatrix} \end{aligned}$$

- 因此 $f(x) = Ax$, 其中 $A = [f(e_1) \quad \cdots \quad f(e_n)]$

6.15 矩阵向量乘积复杂度

- 矩阵 $A \in \mathbb{R}^{m \times n}$ 和向量 $x \in \mathbb{R}^n$ 的乘积 $y = Ax$, 需要 $(2n-1)m$ flops;
- 乘积 $y \in \mathbb{R}^m$, 每个元素需要做向量内积, 需要 $2n-1$ flops;
- 当 n 足够大时, 复杂度近似于 $2mn$;
- 特殊情况
 - A 为对角矩阵: n flops
 - A 为下三角矩阵: n^2 flops
 - A 为稀疏矩阵时: $\text{flops} \ll 2mn$

6.16 例子($f: \mathbb{R}^3 \rightarrow \mathbb{R}^3$)

- f 颠倒向量 x 中的元素的顺序, 一个线性函数 $f(x) = Ax$, 其中

$$A = \begin{bmatrix} 0 & 0 & 1 \\ 0 & 1 & 0 \\ 1 & 0 & 0 \end{bmatrix}, Ax = \begin{bmatrix} 0 & 0 & 1 \\ 0 & 1 & 0 \\ 1 & 0 & 0 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = \begin{bmatrix} x_3 \\ x_2 \\ x_1 \end{bmatrix}$$

- f 对向量 x 中的元素进行升序排序, 非线性;
- f 将向量 x 中的元素替换成相应的绝对值, 非线性;

6.17 反转和循环移位

- 反转矩阵

$$A = \begin{bmatrix} 0 & 0 & \cdots & 0 & 1 \\ 0 & 0 & \cdots & 1 & 0 \\ \vdots & \vdots & \ddots & \vdots & \vdots \\ 0 & 1 & \cdots & 0 & 0 \\ 1 & 0 & \cdots & 0 & 0 \end{bmatrix}, Ax = \begin{bmatrix} x_n \\ x_{n-1} \\ \vdots \\ x_2 \\ x_1 \end{bmatrix}$$


- 循环移位矩阵

$$A = \begin{bmatrix} 0 & 0 & \cdots & 0 & 1 \\ 1 & 0 & \cdots & 0 & 0 \\ 0 & 1 & \cdots & 0 & 0 \\ \vdots & \vdots & \ddots & \vdots & \vdots \\ 0 & 0 & \cdots & 1 & 0 \end{bmatrix}, Ax = \begin{bmatrix} x_n \\ x_1 \\ x_2 \\ \vdots \\ x_{n-1} \end{bmatrix}$$

6.18 平面旋转

$$A = \begin{bmatrix} \cos \theta & -\sin \theta \\ \sin \theta & \cos \theta \end{bmatrix}$$


- Ax 将向量 x 进行旋转，角度为 θ



6.19 节点弧关联矩阵

- 假设有向图 G 有 m 个顶点， n 条弧
- 则关联矩阵 A 大小为 $m \times n$ ，其中

$$A_{ij} = \begin{cases} 1 & \text{如果点 } i \text{ 是弧 } j \text{ 的终点} \\ -1 & \text{如果点 } i \text{ 是弧 } j \text{ 的起点} \\ 0 & \text{其它} \end{cases}$$



$$A = \begin{bmatrix} -1 & -1 & 0 & 1 & 0 \\ 1 & 0 & -1 & 0 & 0 \\ 0 & 0 & 1 & -1 & -1 \\ 0 & 1 & 0 & 0 & 1 \end{bmatrix}$$

6.20 向量卷积

- 向量 $a \in \mathbb{R}^n$ 和向量 $b \in \mathbb{R}^m$ 的卷积是一个 $(n+m-1)$ 维向量 $c \in \mathbb{R}^{n+m-1}$

$$c_k = \sum_{i+j=k+1} a_i b_j, \quad k = 1, \dots, n+m-1$$

- 记为 $c = a * b$

- 例如： $n=4, m=3$

$$c_1 = a_1 b_1$$

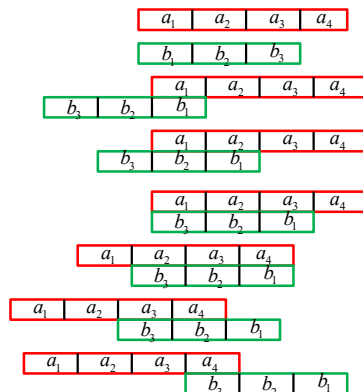
$$c_2 = a_1 b_2 + a_2 b_1$$

$$c_3 = a_1 b_3 + a_2 b_2 + a_3 b_1$$

$$c_4 = a_2 b_3 + a_3 b_2 + a_4 b_1$$

$$c_5 = a_3 b_3 + a_4 b_2$$

$$c_6 = a_4 b_3$$



6.21 向量卷积性质

- 假设向量 a 和 b 分别是多项式 $p(x)$ ， $q(x)$ 的系数

$$p(x)q(x) = c_1 + c_2x + \dots + c_{m+n-1}x^{m+n-2}$$

- 则 $c = a * b$ 是多项式 $p(x)q(x)$ 的系数

- 性质：
 - 对称性： $a * b = b * a$
 - 结合律： $(a * b) * c = a * (b * c)$
 - 如果 $a * b = 0$ ，则 $a=0$ ，或者 $b=0$

6.22 向量和Toeplitz矩阵

- 如果固定 a ,则 $c = a * b$ 是一个线性函数
- 如果固定 b ,则 $c = a * b$ 是一个线性函数
- 例子: 4维向量 a 和3维向量 b , 则 $c = a * b$

$$\begin{bmatrix} c_1 \\ c_2 \\ c_3 \\ c_4 \\ c_5 \\ c_6 \end{bmatrix} = \begin{bmatrix} a_1 & 0 & 0 \\ a_2 & a_1 & 0 \\ a_3 & a_2 & a_1 \\ a_4 & a_3 & a_2 \\ 0 & a_4 & a_3 \\ 0 & 0 & a_4 \end{bmatrix} \begin{bmatrix} b_1 \\ b_2 \\ b_3 \end{bmatrix} = \begin{bmatrix} b_1 & 0 & 0 & 0 \\ b_2 & b_1 & 0 & 0 \\ b_3 & b_2 & b_1 & 0 \\ 0 & b_3 & b_2 & b_1 \\ 0 & 0 & b_3 & b_2 \\ 0 & 0 & 0 & b_3 \end{bmatrix} \begin{bmatrix} a_1 \\ a_2 \\ a_3 \\ a_4 \end{bmatrix}$$

- 上述的矩阵向量乘积中的矩阵被称为Toeplitz矩阵

6.23 Vandermonde矩阵

- 多项式 $p(t)$ 其度为 $n-1$,系数为 x_1, x_2, \dots, x_n

$$p(t) = x_1 + x_2 t + x_3 t^2 + \dots + x_n t^{n-1}$$

- $p(t)$ 在 m 个点中 t_1, t_2, \dots, t_m 的值为

$$\begin{bmatrix} p(t_1) \\ p(t_2) \\ \vdots \\ p(t_m) \end{bmatrix} = \begin{bmatrix} 1 & t_1 & \dots & t_1^{n-1} \\ 1 & t_2 & \dots & t_2^{n-1} \\ \vdots & \vdots & \ddots & \vdots \\ 1 & t_m & \dots & t_m^{n-1} \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix} = Ax$$

- 矩阵 A 被称为Vandermonde矩阵

6.24 离散傅里叶变换(DFT)

- DFT将 n 维复向量 x 映射为 n 维复向量 $y (\mathbb{C}^n \rightarrow \mathbb{C}^n)$

$$y_k = \sum_{\ell=1}^n x_{\ell} e^{-i \frac{2\pi}{n} (k-1)(\ell-1)}, k = 1, \dots, n.$$

$$\begin{bmatrix} y_1 \\ y_2 \\ y_3 \\ \vdots \\ y_n \end{bmatrix} = \begin{bmatrix} 1 & 1 & 1 & \dots & 1 \\ 1 & \omega^{-1} & \omega^{-2} & \dots & \omega^{-(n-1)} \\ 1 & \omega^{-2} & \omega^{-4} & \dots & \omega^{-2(n-1)} \\ \vdots & \vdots & \vdots & \dots & \vdots \\ 1 & \omega^{-(n-1)} & \omega^{-2(n-1)} & \dots & \omega^{-(n-1)(n-1)} \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \\ \vdots \\ x_n \end{bmatrix}$$

- 其中 $\omega = e^{2\pi i/n}$
- DFT矩阵 W 的第 k 行第 l 列的元素为 $W_{kl} = \omega^{-(k-1)(l-1)}$

$$x_{\ell} = \frac{1}{n} \sum_{k=1}^n y_k e^{i \frac{2\pi}{n} (k-1)(\ell-1)}, \ell = 1, \dots, n.$$

6.25 半正定矩阵

- 对称矩阵 $A \in \mathbb{R}^{n \times n}$ 称为**半正定矩阵**, 满足以下条件:

$$x^T A x \geq 0 \quad \forall x \in \mathbb{R}^n$$

- 对称矩阵 $A \in \mathbb{R}^{n \times n}$ 称为**正定矩阵**, 满足以下条件:

$$x^T A x > 0 \quad \forall x \neq 0$$

这是半正定矩阵的一个子集。

- 注: 如果对称矩阵 $A \in \mathbb{R}^{n \times n}$, 则 $x^T A x$ 是函数:

$$x^T A x = \sum_{i=1}^n \sum_{j=1}^n x_i A_{ij} x_j = \sum_{i=1}^n A_{ii} x_i^2 + 2 \sum_{i>j} A_{ij} x_i x_j$$

这叫做**二次型**。

6.27 半正定矩阵例子

$$A = \begin{bmatrix} 9 & 6 \\ 6 & a \end{bmatrix}$$

$$x^T A x = 9x_1^2 + 12x_1x_2 + ax_2^2 = (3x_1 + 2x_2)^2 + (a-4)x_2^2$$

- 如果 $a > 4$, 矩阵 A 为正定矩阵:

$$x^T A x > 0 \quad \forall x \neq 0$$

- 如果 $a = 4$, 矩阵 A 为半正定矩阵, 但不是正定矩阵:

$$x^T A x \geq 0 \quad \forall x, \quad x^T A x = 0 \quad \exists x = \begin{bmatrix} 2 \\ -3 \end{bmatrix}$$

- 如果 $a < 4$, 矩阵 A 不是半正定矩阵:

$$x^T A x < 0 \quad \exists x = \begin{bmatrix} 2 \\ -3 \end{bmatrix}$$

6.28 正定矩阵性质

- 正定矩阵 A 都是非奇异的

$$Ax = 0 \quad \Rightarrow \quad x^T Ax = 0 \quad \Rightarrow \quad x = 0$$

(最后一步由正定性得到的)

- 正定矩阵 A 有正的对角元素

$$A_{ii} = e_i^T A e_i > 0$$

- 每个半正定矩阵 A 都有非负的对角元素

$$A_{ii} = e_i^T A e_i \geq 0$$

6.29 Gram矩阵

Gram矩阵 A 的定义:

$$A = B^T B$$

- 每个Gram矩阵都是半正定的:

$$x^T A x = x^T B^T B x = \|Bx\|_2^2 \geq 0 \quad \forall x$$

- 如果Gram矩阵是正定的, 则要满足:

$$x^T A x = x^T B^T B x = \|Bx\|_2^2 > 0 \quad \forall x \neq 0$$

也就是说, B 的列向量是线性无关的。

6.3 矩阵范数

- 矩阵范数(Matrix norm): 向量空间中存在一个函数 $\|\cdot\|: \mathbb{R}^{m \times n} \rightarrow \mathbb{R}$, 且满足以下条件:

- 齐次性: $\|\alpha A\| = |\alpha| \|A\|$, $\alpha \in \mathbb{R}$ 且 $A \in \mathbb{R}^{m \times n}$;
 - 三角不等式: $\|A + B\| \leq \|A\| + \|B\|$, $A, B \in \mathbb{R}^{m \times n}$;
 - 非负性: $\|A\| \geq 0$, $A \in \mathbb{R}^{m \times n}$ 且 $\|A\| = 0 \Leftrightarrow A = 0$;
- 则称 $\|\cdot\|$ 为矩阵范数。

- 例子: 向量空间 $\mathbb{R}^{m \times n}$ 矩阵范数:

- F-范数(Frobenius norm): $\|A\|_F = \left(\sum_{i=1}^n \sum_{j=1}^n a_{ij}^2 \right)^{1/2}$.

$$\|A\|_F \geq 0, \|\alpha A\|_F = |\alpha| \|A\|_F, \alpha \in \mathbb{R}.$$

$$\|A + B\|_F = \left(\sum_{i=1}^n \sum_{j=1}^n (a_{ij} + b_{ij})^2 \right)^{1/2} \leq \left(\sum_{i=1}^n \sum_{j=1}^n (a_{ij})^2 \right)^{1/2} + \left(\sum_{i=1}^n \sum_{j=1}^n (b_{ij})^2 \right)^{1/2}$$

$$\text{Minkowski不等式} = \|A\|_F + \|B\|_F$$

6.3 算子范数

设 $x \in \mathbb{R}^n, A \in \mathbb{R}^{m \times n}, \|\cdot\|_v$ 为一种向量范数。则 $\frac{\|Ax\|_v}{\|x\|_v}$ 对所有 $x \neq 0$ 有最大值, 令

$$\|A\|_v = \max_{x \neq 0} \left\{ \frac{\|Ax\|_v}{\|x\|_v} \right\} = \max_{x \neq 0} \left\{ \left\| A \frac{x}{\|x\|_v} \right\|_v \right\} = \max_{\|y\|_v=1} \{ \|Ay\|_v \} \quad \text{---(1)}$$

可以验证 $\|A\|_v$ 满足矩阵范数定义。

$$\|A\|_v \geq 0, \|\alpha A\|_v = |\alpha| \|A\|_v, \quad \alpha \in \mathbb{R}$$

$$\|A+B\|_v = \max_{\|y\|_v=1} \|(A+B)y\|_v \leq \max_{\|y\|_v=1} \{ \|Ay\|_v + \|By\|_v \}$$

$$\leq \max_{\|y\|_v=1} \|Ay\|_v + \max_{\|y\|_v=1} \|By\|_v = \|A\|_v + \|B\|_v$$

由(1)式确定的 $\|A\|_v$ 称为从属于给定向量范数 $\|x\|_v$ 的矩阵范数, 简称为从属范数或算子范数

6.3 算子范数

由定义 $\|A\|_v = \max_{x \neq 0} \left\{ \frac{\|Ax\|_v}{\|x\|_v} \right\}$ 可得

$$\frac{\|Ax\|_v}{\|x\|_v} \leq \|A\|_v \Rightarrow \|Ax\|_v \leq \|A\|_v \|x\|_v$$

称向量范数和算子范数相容。

$$A \in \mathbb{R}^{m \times n}, B \in \mathbb{R}^{n \times p}$$

$$\|AB\|_v = \max_{x \neq 0} \left\{ \frac{\|ABx\|_v}{\|x\|_v} \right\} \leq \max_{x \neq 0} \left\{ \frac{\|A\|_v \|Bx\|_v}{\|x\|_v} \right\} \leq \|A\|_v \max_{x \neq 0} \left\{ \frac{\|Bx\|_v}{\|x\|_v} \right\} = \|A\|_v \|B\|_v$$

即算子范数服从乘法范数相容性。

根据向量的常用范数矩阵 $A \in \mathbb{R}^{m \times n}$ 的算子范数

$$1) \|A\|_1 = \max_{x \neq 0} \left(\|Ax\|_1 / \|x\|_1 \right) = \max_{1 \leq j \leq n} \sum_{i=1}^m |a_{ij}|$$

A 的每列绝对值之和的最大值, 称为 A 的列范数

$$2) \|A\|_\infty = \max_{x \neq 0} \left(\|Ax\|_\infty / \|x\|_\infty \right) = \max_{1 \leq i \leq m} \sum_{j=1}^n |a_{ij}|$$

A 的每行绝对值之和的最大值, 称为 A 的行范数

$$3) \|A\|_2 = \max_{x \neq 0} \left(\|Ax\|_2 / \|x\|_2 \right) = \sqrt{\lambda_{\max}(A^T A)}$$

$\lambda_{\max}(A^T A)$ 为 $A^T A$ 的特征值的绝对值的最大值, 称为 A 的 2 范数

6.4 条件数

■ 定义: 非奇异矩阵 A 的条件数(condition number):

$$\kappa(A) = \|A\|_2 \|A^{-1}\|_2$$

性质:

- 对于所有 A , 有 $\kappa(A) \geq 1$;
- 如果 $\kappa(A)$ 比较小(接近1), x 的相对误差接近 b 的相对误差;
- 如果 $\kappa(A)$ 比较大, x 的相对误差比 b 的相对误差大得多。
- 由矩阵 A 定义的问题, 称为适定问题或病态问题。

7.1 矩阵左逆

- 当一个矩阵X满足 $XA = I$ 时，X被称为A的左逆；
- 当左逆存在时，则称A是可左逆的；
- 当左逆存在时，则A至少有一个左逆；

$$A = \begin{bmatrix} -3 & -4 \\ 4 & 6 \\ 1 & 1 \end{bmatrix}$$

- 矩阵A是可左逆的，其左逆矩阵有两个

$$B = \frac{1}{9} \begin{bmatrix} -11 & -10 & 16 \\ 7 & 8 & -11 \end{bmatrix}$$

$$C = \frac{1}{2} \begin{bmatrix} 0 & -1 & 6 \\ 0 & 1 & -4 \end{bmatrix}$$

7.2 矩阵右逆

- 若矩阵X满足 $AX = I$ ，则称X为矩阵A的右逆；
- 当右逆存在时，则称A是可右逆的；
- 当右逆存在时，则A至少有一个右逆；

$$B = \begin{bmatrix} 1 & 0 & 1 \\ 0 & 1 & 1 \end{bmatrix}$$

- 矩阵B可右逆，以下矩阵都是B的右逆

$$D = \frac{1}{2} \begin{bmatrix} 1 & -1 \\ -1 & 1 \\ 1 & 1 \end{bmatrix}, E = \begin{bmatrix} 1 & 0 \\ 0 & 1 \\ 0 & 0 \end{bmatrix}, G = \begin{bmatrix} 1 & -1 \\ 0 & 0 \\ 0 & 1 \end{bmatrix}$$

7.3 性质

- 维度：一个大小为 $m \times n$ 的矩阵，其左逆或右逆的维度为 $n \times m$

- A的左逆为X当且仅当 X^T 是 A^T 的右逆

$$A^T X^T = (XA)^T = I$$

- A的右逆为X当且仅当 X^T 是 A^T 的左逆

$$X^T A^T = (AX)^T = I$$

7.4 矩阵的逆

- 如果矩阵A存在左逆和右逆，则左逆和右逆一定相等

$$XA = I, AY = I \Rightarrow X = XI = X(AY) = (XA)Y = Y$$

- 此时X称为矩阵的逆，记作 A^{-1}
- 当矩阵的逆存在时，则称矩阵A可逆
- 例子：

$$A = \begin{bmatrix} -1 & 1 & 3 \\ 1 & -1 & 1 \\ 2 & 2 & 2 \end{bmatrix}, A^{-1} = \frac{1}{4} \begin{bmatrix} 2 & 4 & 1 \\ 0 & -2 & 1 \\ -2 & -2 & 0 \end{bmatrix}, AA^{-1} = A^{-1}A = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix}$$

7.6 线性方程组求解

- 如果矩阵A可左逆, 假设X是矩阵A的左逆, 则

$$Ax = b \Rightarrow x = XAx = Xb$$

至多一个解, 如有解则 $x = Xb$ 。

- 如果矩阵A可右逆, 假设Y是矩阵A的右逆, 则

为什么?

$$x = Yb \Rightarrow Ax = AYb = b$$

至少一个解, 即 $x = Yb$ 。

- 如果矩阵A可逆的, 假设X是矩阵A的逆, 则

$$Ax = b \Rightarrow x = A^{-1}b$$

唯一解。

7.7 非奇异矩阵

- 对于方阵 $A \in \mathbb{R}^{n \times n}$, 以下条件都是等价的:

1. A可左逆
2. A的列向量线性无关
3. A可右逆
4. A的行向量线性无关

- 此时矩阵A为非奇异矩阵, 条件1与3, 可得A为可逆矩阵。

非奇异矩阵 \Leftrightarrow 可逆矩阵。

7.8 证明1->2

- 证明: A可左逆, 则A列向量线性无关
- 假设A的左逆是B, 则

$$\begin{aligned} Ax = 0 &\Rightarrow BAx = 0 \\ &\Rightarrow IX = 0 \end{aligned}$$

- 假设A的列向量 $A = [a_1, a_2, \dots, a_n]$

$$Ax = x_1 a_1 + x_2 a_2 + \dots + x_n a_n = 0$$

则当该等式 $Ax = 0$ 成立时, 其解 $x = 0$, 则A的列向量线性无关。

如果 $A \in \mathbb{R}^{m \times n}$, 则有 $m \geq n!$ 高或方的矩阵 $A = \begin{bmatrix} 1 & 0 \\ 0 & 1 \\ 0 & 0 \end{bmatrix}$

7.8 证明1->2

- 矩阵A有左逆X, 则A列向量线性无关

如果 $A \in \mathbb{R}^{m \times n}$, 根据维度定理则有 $m \geq n!$

$$A = \begin{bmatrix} 1 & 0 \\ 0 & 1 \\ 0 & 0 \end{bmatrix} \quad \text{高或方的矩阵}$$

- 假设A的列向量 $A = [a_1, a_2, \dots, a_n]$

$$Ax = x_1 a_1 + x_2 a_2 + \dots + x_n a_n = b$$

$$Ay = y_1 a_1 + y_2 a_2 + \dots + y_n a_n = b$$

$$Ax - Ay = A(x - y) = 0 \Rightarrow x = y$$

当 $b \in \mathbb{R}^m, b \notin \{y | y = Ax, x \in \mathbb{R}^n\}$ 时, 无解!

$Ax = b$ 至多一个解, 如有解则 $x = Xb$ 。

$$b = \begin{bmatrix} 1 \\ 1 \\ 1 \end{bmatrix}$$

7.9 证明2->3

- 证明：若方阵A列向量线性无关，则A可右逆
- 假设A ∈ ℝ^{n×n}为方阵且列向量线性无关 $A = [a_1, a_2, \dots, a_n]$
- 则对于任意向量b ∈ ℝⁿ，则向量组[a₁, a₂, ..., a_n, b] 线性相关，存在不全为0，使得以下等式成立

$$x_1 a_1 + x_2 a_2 + \dots + x_n a_n + x_{n+1} b = 0$$

- 因为A列向量线性无关，则x_{n+1} ≠ 0，即b是A列向量的线性组合；

$$b = -\frac{x_1}{x_{n+1}} a_1 - \frac{x_2}{x_{n+1}} a_2 - \dots - \frac{x_n}{x_{n+1}} a_n$$

- 存在向量c₁, ..., c_n ∈ ℝⁿ,使得Ac₁ = e₁, Ac₂ = e₂, ..., Ac_n = e_n;
- 则矩阵C = [c₁ c₂ ... c_n] 是矩阵A的右逆, AC = I.

7.13 非奇异Gram矩阵

引理：矩阵A ∈ ℝ^{m×n}, G = A^TA,
矩阵A列向量线性无关 ⇔ "Gram矩阵G非奇异"

证明：“⇒”假设矩阵A列向量线性无关，A^TA奇异。
则存在A^TAx=0, x ≠ 0, 可得x^TA^TAx=||Ax||₂²=0,
即Ax=0与列向量线性无关矛盾。

“⇐”假设A^TA非奇异, 矩阵A列向量线性相关。

则有Ax=0, x ≠ 0, 可得A^TAx=0,

即A^TA是奇异矩阵。

7.14 伪逆

- 矩阵A ∈ ℝ^{m×n}，当m≥n时，列向量线性无关，即A的Gram矩阵可逆；
- A的伪逆A⁺定义：

$$A^+ = (A^T A)^{-1} A^T$$

则A的伪逆存在。

- A⁺为矩阵A的左逆：

$$A^+ A = (A^T A)^{-1} A^T A = (A^T A)^{-1} (A^T A) = I$$

- 当A为方阵，伪逆等于矩阵的逆：

$$(A^T A)^{-1} A^T = A^{-1} A^{-T} A^T = A^{-1}$$

7.14 伪逆

- 矩阵A ∈ ℝ^{m×n}，当m≤n时，且行向量线性无关，则AA^T可逆。
- A^T列向量线性无关，即(A^T)^TA^T=AA^T非奇异；
- 定义伪逆：

$$A^\dagger = A^T (AA^T)^{-1}$$

- 伪逆A[†]为A的右逆

$$AA^\dagger = AA^T (AA^T)^{-1} = (AA^T)^{-1} (AA^T) = I$$

- 当A为方阵时，右逆等于矩阵的逆

$$A^\dagger = A^T (AA^T)^{-1} = A^T A^{-T} A^{-1} = A^{-1}$$

7.15 伪逆

- 以下三个结论为等价的，对于实矩阵A
 - A是可左逆的
 - A的列向量线性无关
 - $A^T A$ 为非奇异矩阵

作业 11.2 11.3

- 以下三个结论为等价的，对于实矩阵A
 - A是可右逆的
 - A的行向量线性无关
 - AA^T 为非奇异矩阵

8.1 正交单位向量

- 如果一个向量集合 $a_1, a_2, \dots, a_n \in \mathbb{R}^m$ 满足：
 - 向量有单位范数： $\|a_i\| = 1$ 。
 - 向量之间相互正交：如果 $i \neq j$ ，有 $a_i^T a_j = 0$ 。则称这些向量是**标准正交**的。

- 例子：

$$\begin{bmatrix} 0 \\ 0 \\ -1 \end{bmatrix}, \quad \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \\ 0 \end{bmatrix}, \quad \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ -1 \\ 0 \end{bmatrix}$$

8.2 标准列正交矩阵

- 如果A的Gram矩阵为单位矩阵，则 $A \in \mathbb{R}^{m \times n}$ 具有**标准正交列**：

$$\begin{aligned} A^T A &= [a_1 \ a_2 \ \cdots \ a_n]^T [a_1 \ a_2 \ \cdots \ a_n] \\ &= \begin{bmatrix} a_1^T a_1 & a_1^T a_2 & \cdots & a_1^T a_n \\ a_2^T a_1 & a_2^T a_2 & \cdots & a_2^T a_n \\ \vdots & \vdots & \ddots & \vdots \\ a_n^T a_1 & a_n^T a_2 & \cdots & a_n^T a_n \end{bmatrix} \\ &= \begin{bmatrix} 1 & 0 & \cdots & 0 \\ 0 & 1 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & 1 \end{bmatrix} = I \end{aligned}$$

8.3 矩阵-向量乘积

- 如果 $A \in \mathbb{R}^{m \times n}$ 具有**标准正交列**，则线性函数 $f(x) = Ax$ ：
 - 保持原内积：

$$\langle Ax, Ay \rangle = (Ax)^T (Ay) = x^T A^T Ay = x^T y$$

- 保持原范数：

$$\|Ax\|_2 = \left((Ax)^T (Ax) \right)^{1/2} = (x^T x)^{1/2} = \|x\|_2$$

- 保持原距离：

$$\|Ax - Ay\|_2 = \left((Ax - Ay)^T (Ax - Ay) \right)^{1/2} = ((x - y)^T (x - y))^{1/2} = \|x - y\|_2$$

- 保持原角度：

$$\angle(Ax, Ay) = \arccos \left(\frac{(Ax)^T (Ay)}{\|Ax\|_2 \|Ay\|_2} \right) = \arccos \left(\frac{x^T y}{\|x\|_2 \|y\|_2} \right) = \angle(x, y)$$

8.4 左可逆性

- 如果矩阵 $A \in \mathbb{R}^{m \times n}$ 有标准正交列，则：
 - A 是左可逆的，其左逆为 A^T ，根据定义：

$$A^T A = I$$

- A 有线性无关的列向量：

$$Ax = 0 \Rightarrow A^T Ax = x = 0$$

- A 是高的或者方的，即 $m \geq n$ 。

列向量 $a_1, a_2, \dots, a_n \in \mathbb{R}^m$ ，维度定理 $n \leq m$

8.5 正交矩阵

- 定义：所有列两两相互正交的方形实矩阵称为**正交矩阵**。
- 正交矩阵满足非奇异性，即如果方形矩阵 A 是正交的，则：
 - A 是可逆的，左逆等于右逆，且它的逆为 A^T ：

$$\left. \begin{array}{l} A^T A = I \\ A \text{ 是方的} \end{array} \right\} \Rightarrow A \text{ 是可逆的} \Rightarrow AA^T = I$$

- A^T 也是一个正交矩阵。
- A 的行是标准正交的，即范数为1且相互正交。
- 注意：如果 $A \in \mathbb{R}^{m \times n}$ 有标准正交列以及 $m > n$ ，则 $AA^T \neq I$ 。

8.6 置换矩阵

- 让 $\pi = (\pi_1, \pi_2, \dots, \pi_n)$ 为 $(1, 2, \dots, n)$ 的一个重新排序的排列。
- 将 π 与一个置换矩阵 $A \in \mathbb{R}^{n \times n}$ 联系起来：

$$A_{i\pi_i} = 1, \quad A_{ij} = 0 \text{ 如果 } j \neq \pi_i$$

- Ax 是 x 的一个置换： $Ax = (x_{\pi_1}, x_{\pi_2}, \dots, x_{\pi_n})$ 。
- A 在每一行和每一列中都有一个等于1的元素。
- 置换矩阵满足正交性，即所有置换矩阵都是正交的：

- $A^T A = I$ ，因为 A 的每一行有一个元素等于1：

$$(A^T A)_{ij} = \sum_{k=1}^n A_{ki} A_{kj} = \begin{cases} 1 & i = j \\ 0 & \text{其它} \end{cases}$$

- $A^T = A^{-1}$ 是逆置换矩阵。

8.6 置换矩阵例子

- 让 $\pi = (\pi_1, \pi_2, \dots, \pi_n)$ 为 $(1, 2, \dots, n)$ 的一个重新排序的排列。
- 若 $\{1, 2, 3, 4\}$ 的置换为：

$$(\pi_1, \pi_2, \pi_3, \pi_4) = (2, 4, 1, 3)$$

- 相应的置换矩阵及其逆矩阵为：

$$A = \begin{bmatrix} 0 & 1 & 0 & 0 \\ 0 & 0 & 0 & 1 \\ 1 & 0 & 0 & 0 \\ 0 & 0 & 1 & 0 \end{bmatrix}, \quad A^{-1} = A^T = \begin{bmatrix} 0 & 0 & 1 & 0 \\ 1 & 0 & 0 & 0 \\ 0 & 0 & 0 & 1 \\ 0 & 1 & 0 & 0 \end{bmatrix}$$


- A^T 是与置换相关的置换矩阵：

$$(\tilde{\pi}_1, \tilde{\pi}_2, \tilde{\pi}_3, \tilde{\pi}_4) = (3, 1, 4, 2)$$

8.7 平面旋转

- 在一个平面的旋转可以用矩阵表示为：

$$A = \begin{bmatrix} \cos \theta & -\sin \theta \\ \sin \theta & \cos \theta \end{bmatrix}$$



- 在 \mathbb{R}^n 的坐标平面上旋转：例如，

$$A = \begin{bmatrix} \cos \theta & 0 & -\sin \theta \\ 0 & 1 & 0 \\ \sin \theta & 0 & \cos \theta \end{bmatrix}$$

描述了在 \mathbb{R}^3 中 (x_1, x_3) 平面的旋转。

8.8 反射算子

- 反射算子(reflector)：一个矩阵的形式为：

$$A = I - 2aa^T$$


其中，向量 a 满足 $\|a\|_2 = 1$ 。

- 性质：

- 反射矩阵(reflector matrix)是对称的 $A^T = A$
- 反射矩阵(reflector matrix)是正交的

$$A^T A = (I - 2aa^T)(I - 2aa^T) = I - 4aa^T + 4aa^T aa^T = I$$

8.8.1 反射算子的几何解释



- $H = \{u | a^T u = 0\}$ 是与 a 正交的向量的(超)平面。

- 如果 $\|a\|_2 = 1$, x 在 H 上的投影为：

$$y = x - (a^T x)a = x - a(a^T x) = (I - aa^T)x$$

Gram-Schmidt正交算法

- x 关于超平面 H 的对称点 z 由其与反射算子的乘积给出：

$$z = y + (y - x) = (I - 2aa^T)x$$

8.8.2 练习

- 假设 $\|a\|_2 = 1$ ；给出 x 在 $H = \{u | a^T u = 0\}$ 上的投影为：

$$y = x - (a^T x)a$$

- 1、证明： $y \in H$ 。

$$a^T y = a^T (x - a(a^T x)) = a^T x - (a^T a)(a^T x) = a^T x - a^T x = 0$$

- 2、考虑任意 $z \in H (z \neq y)$ ，证明 $\|x - z\|_2^2 > \|x - y\|_2^2$ 。

$$\begin{aligned} \|x - z\|_2^2 &= \|x - y + y - z\|_2^2 \\ &= \|x - y\|_2^2 + 2(x - y)^T (y - z) + \|y - z\|_2^2 \\ &= \|x - y\|_2^2 + 2(a^T x)a^T (y - z) + \|y - z\|_2^2 \\ &= \|x - y\|_2^2 + \|y - z\|_2^2 \quad (\text{因为 } a^T y = a^T z = 0) \\ &> \|x - y\|_2^2 \end{aligned}$$

8.12 值域范围

- 一个向量集合张成的空间是其所有线性组合的集合：

$$\text{span}(a_1, a_2, \dots, a_n) = \{x_1 a_1 + x_2 a_2 + \dots + x_n a_n \mid x \in \mathbb{R}^n\}$$

- 矩阵 $A \in \mathbb{R}^{m \times n}$ 的范围为其列向量张成的空间：

$$\text{range}(A) = \{Ax \mid x \in \mathbb{R}^n\}$$

- 例子：

$$\text{range}\left(\begin{bmatrix} 1 & 0 \\ 1 & 2 \\ 0 & -1 \end{bmatrix}\right) = \left\{ \begin{bmatrix} x_1 \\ x_1 + 2x_2 \\ -x_2 \end{bmatrix} \mid x_1, x_2 \in \mathbb{R} \right\}$$

8.13 值域投影

- 假设矩阵 $A \in \mathbb{R}^{m \times n}$ 具有标准正交列，向量 Ax 与 b 的最短距离：

$$\min_x \|Ax - b\|_2^2$$

$$f(x) = \|Ax - b\|_2^2 = (Ax - b)^T (Ax - b) = x^T A^T A x - 2x^T A^T b + b^T b$$

$$= x^T x - 2x^T A^T b + b^T b, \quad \because A^T A = I$$

$$\nabla f(x) = 2x - 2A^T b = 0 \Rightarrow x = A^T b$$

$$Ax = AA^T b \in \text{range}(A)$$

$AA^T b$ 称为向量 $b \in \mathbb{R}^m$ 在 $\text{range}(A)$ 上的正交投影。



- $\hat{x} = A^T b$ 满足 $\|A\hat{x} - b\| < \|Ax - b\|$, 对于所有 $x \neq \hat{x}$ 。

8.13.1 验证

- b 到 $\text{range}(A)$ 内任意点 Ax 的距离的平方和为：

$$\begin{aligned} \|Ax - b\|_2^2 &= \|A(x - \hat{x}) + A\hat{x} - b\|_2^2 \quad (\text{其中 } \hat{x} = A^T b) \\ &= \|A(x - \hat{x})\|_2^2 + \|A\hat{x} - b\|_2^2 + 2(x - \hat{x})^T A^T (A\hat{x} - b) \\ &= \|A(x - \hat{x})\|_2^2 + \|A\hat{x} - b\|_2^2 \\ &= \|(x - \hat{x})\|_2^2 + \|A\hat{x} - b\|_2^2 \\ &\geq \|A\hat{x} - b\|_2^2 \end{aligned}$$

当且仅当 $x = \hat{x}$, 等号成立。

- 第3行成立是因为 $A^T(A\hat{x} - b) = \hat{x} - A^T b = 0$. $\because A^T A = I$

$$\begin{aligned} \|A(x - \hat{x})\|_2^2 &= (A(x - \hat{x}))^T A(x - \hat{x}) = (x - \hat{x})^T A^T A(x - \hat{x}) = (x - \hat{x})^T (x - \hat{x}) \\ &= \|x - \hat{x}\|_2^2 \end{aligned}$$

8.15 Unitary矩阵

- 定义：列正交的方形复数矩阵称为酉矩阵。

- 酉矩阵的逆：

$$\left. \begin{matrix} A^H A = I \\ A \text{ 是方的} \end{matrix} \right\} \Rightarrow AA^H = I$$

- 酉矩阵是具有逆 A^H 的非奇异矩阵。

- 如果 A 是酉矩阵，那么 A^H 也是酉矩阵。

8.16 离散傅里叶变换矩阵

- 离散傅里叶变换矩阵 W : ($\omega = e^{2\pi j/n}$, $j = \sqrt{-1}$)

$$W = \begin{bmatrix} 1 & 1 & 1 & \cdots & 1 \\ 1 & \omega^{-1} & \omega^{-2} & \cdots & \omega^{-(n-1)} \\ 1 & \omega^{-2} & \omega^{-4} & \cdots & \omega^{-2(n-1)} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & \omega^{-(n-1)} & \omega^{-2(n-1)} & \cdots & \omega^{-(n-1)(n-1)} \end{bmatrix}$$

- 矩阵 $(1/\sqrt{n})W$ 是酉矩阵:

$$\frac{1}{n} W^H W = \frac{1}{n} W W^H = I$$

- W 的逆 $W^{-1} = (1/n)W^H$.

- n 维向量 x 的离散傅里叶反变换是 $W^{-1}x = (1/n)W^H x$.

8.17 DFT矩阵的Gram矩阵

证明 $W^H W = nI$ 。

作业 11.4

- W 的共轭转置为:

$$W^H = \begin{bmatrix} 1 & 1 & 1 & \cdots & 1 \\ 1 & \omega^1 & \omega^2 & \cdots & \omega^{n-1} \\ 1 & \omega^2 & \omega^4 & \cdots & \omega^{2(n-1)} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & \omega^{n-1} & \omega^{2(n-1)} & \cdots & \omega^{(n-1)(n-1)} \end{bmatrix}$$

- Gram矩阵的第 i, j 个元素为:

$$(W^H W)_{ij} = 1 + \omega^{i-j} + \omega^{2(i-j)} + \cdots + \omega^{(n-1)(i-j)}$$

$$(W^H W)_{ii} = n, \quad (W^H W)_{ij} = \frac{\omega^{n(i-j)} - 1}{\omega^{i-j} - 1} = 0 \text{ 如果 } i \neq j$$

最后一步因为 $\omega^n = 1$ 。

9.2 前向回代

- 问题: 当 A 是具有非零对角元素的下三角矩阵时, 解 $Ax = b$ 。

- 前向回代(Forward Substitution)算法求解:

$$A = \begin{bmatrix} A_{11} & 0 & \cdots & 0 & 0 \\ A_{21} & A_{22} & \cdots & 0 & 0 \\ \vdots & \vdots & \ddots & \vdots & \vdots \\ A_{n-1,1} & A_{n-1,2} & \cdots & A_{n-1,n-1} & 0 \\ A_{n1} & A_{n2} & \cdots & A_{n,n-1} & A_{nn} \end{bmatrix}$$

$$x_1 = b_1 / A_{11}$$

$$x_2 = (b_2 - A_{21}x_1) / A_{22}$$

$$x_3 = (b_3 - A_{31}x_1 - A_{32}x_2) / A_{33}$$

\vdots

$$x_n = (b_n - A_{n1}x_1 - A_{n2}x_2 - \cdots - A_{n,n-1}x_{n-1}) / A_{nn}$$

- 时间复杂度: $1+3+5+\cdots+(2n-1)=n^2$ flops

9.4 三角矩阵的逆矩阵

- 对角元素非零的三角矩阵 A 是非奇异的, 即:

$$Ax = 0 \Rightarrow x = 0$$

- A 的逆可以通过逐列解方程 $AX = I$ 来计算得到:

$$A[x_1 \ x_2 \ \cdots \ x_n] = [e_1 \ e_2 \ \cdots \ e_n]$$

(x_i 是矩阵 X 的第 i 列向量)

$$x_1 = b_1 / A_{11}$$

$$x_2 = (b_2 - A_{21}x_1) / A_{22}$$

$$x_3 = (b_3 - A_{31}x_1 - A_{32}x_2) / A_{33}$$

\vdots

$$x_n = (b_n - A_{n1}x_1 - A_{n2}x_2 - \cdots - A_{n,n-1}x_{n-1}) / A_{nn}$$

- 下三角矩阵的逆是下三角矩阵

- 上三角矩阵的逆是上三角矩阵

- 上/下三角矩阵 $A \in \mathbb{R}^{n \times n}$ 逆的复杂度:

$$n^2 + (n-1)^2 + \cdots + 1 \approx \frac{1}{3}n^3 \text{ flops}$$

9.5 QR分解

- 如果矩阵 $A \in \mathbb{R}^{m \times n}$ 的列向量线性无关, 则可以将其分解为

$$A = [a_1 \ a_2 \ \cdots \ a_n] = [q_1 \ q_2 \ \cdots \ q_n] \begin{bmatrix} R_{11} & R_{12} & \cdots & R_{1n} \\ 0 & R_{22} & \cdots & R_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & R_{nn} \end{bmatrix}$$

Gram-Schmidt(正交化) $\tilde{q}_i = a_i - (q_1^T a_i)q_1 - \cdots - (q_{i-1}^T a_i)q_{i-1} \quad R_{ji} = (q_j^T a_i)$

- 向量 $q_1, \dots, q_n \in \mathbb{R}^m$ 是标准正交向量:

$$\|q_i\|_2 = 1, \quad q_i^T q_j = 0, \text{ if } i \neq j$$

- 对角元素 R_{ii} 是非零的。
- 若 $R_{ii} < 0$, 改变 R_{ii}, \dots, R_{in} 和向量 q_i 的符号。
- 大多数定义要求 $R_{ii} > 0$, 使得 Q 和 R 是唯一的。

9.5.1 矩阵的QR分解

- 如果 $A \in \mathbb{R}^{m \times n}$ 的列向量是线性无关的, 则可以将其分解为

$$A = QR$$

- Q因子:**

- $Q \in \mathbb{R}^{m \times n}$ 具有标准正交列 ($Q^T Q = I$)
- 如果 A 是方阵 ($m=n$), 则 Q 是正交的 ($Q^T Q = Q Q^T = I$)

- R因子:**

- $R \in \mathbb{R}^{n \times n}$ 的上三角矩阵
- R 是非奇异的(对角元素是非零的)

9.5.1 矩阵的QR分解

- QR分解步骤:

1. 设矩阵 A 的列向量依次为 a_1, a_2, \dots, a_n , 由于 A 为非奇异矩阵, 则列向量线性无关;
2. 对列向量 a_1, a_2, \dots, a_n 按照Gram-Schmidt方法进行正交化, 然后单位化;
3. 单位化得到的标准正交向量 q_1, q_2, \dots, q_n , 即得到标准正交矩阵 Q ;
4. 根据 $R = Q^{-1}A \Rightarrow R = Q^T A$, 得到上三角矩阵 R ;
5. QR分解 $A = QR$ 。

9.5.1 矩阵中的QR分解

- 矩阵 A 的QR分解过程:

$$A = \begin{bmatrix} 1 & 1 & 0 \\ 1 & -1 & 1 \\ 0 & 0 & 2 \end{bmatrix}$$

- 令 $a_1 = (1, 1, 0)^T, a_2 = (1, -1, 0)^T, a_3 = (0, 1, 2)^T$, 由Schmidt方法正交单位化后, 得到 $q_1 = \left(\frac{1}{\sqrt{2}}, \frac{1}{\sqrt{2}}, 0\right)^T, q_2 = \left(\frac{1}{\sqrt{2}}, -\frac{1}{\sqrt{2}}, 0\right)^T, q_3 = (0, 0, 1)^T$ 。

- 所以 $a_1 = \sqrt{2} q_1, a_2 = \sqrt{2} q_2, a_3 = \frac{1}{\sqrt{2}} q_1 - \frac{1}{\sqrt{2}} q_2 + 2q_3$ 。

$$A = QR = \begin{bmatrix} \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} & 0 \\ \frac{1}{\sqrt{2}} & -\frac{1}{\sqrt{2}} & 0 \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} \sqrt{2} & 0 & \frac{1}{\sqrt{2}} \\ 0 & \sqrt{2} & -\frac{1}{\sqrt{2}} \\ 0 & 0 & 2 \end{bmatrix}$$

9.6 QR分解和(伪)逆

- 具有线性无关列向量的矩阵A的伪逆为:

$$A^\dagger = (A^T A)^{-1} A^T$$

- 将A的伪逆表示为QR因子:

$$\begin{aligned} A^\dagger &= ((QR)^T (QR))^{-1} (QR)^T \\ &= (R^T Q^T Q R)^{-1} R^T Q^T \\ &= (R^T R)^{-1} R^T Q^T \quad (Q^T Q = I) \\ &= R^{-1} R^{-T} R^T Q^T \quad (R \text{是非奇异的}) \\ &= R^{-1} Q^T \end{aligned}$$

- 对于方阵非奇异矩阵A, 其逆为:

$$A^{-1} = (QR)^{-1} = R^{-1} Q^T$$

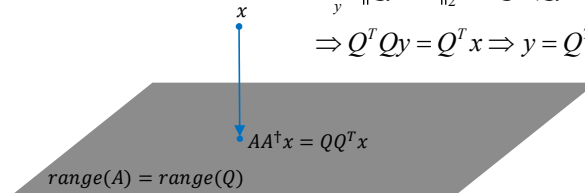
9.8 值域上的投影

- 结合 $A = QR$ 和 $A^\dagger = R^{-1} Q^T$, 可得:

$$AA^\dagger = QRR^{-1}Q^T = QQ^T$$

注意在 AA^\dagger 中乘积的顺序与 $A^\dagger A = I$ 的差异。

- $QQ^T x$ 是 x 在 Q 值域上的投影:

$$\begin{aligned} \min_y \|Qy - x\|_2^2 &\Rightarrow Q^T(Qy - x) = 0 \\ &\Rightarrow Q^T Qy = Q^T x \Rightarrow y = Q^T x \\ &\Rightarrow AA^\dagger x = QQ^T x \end{aligned}$$


9.11.2 时间复杂度

Gram-Schmidt方法第k次循环的复杂度:

- $a_k \in \mathbb{R}^m$ 有 $k-1$ 个 $q_i^T a_k$ 内积操作: $(k-1)(2m-1)$ flops,
- 计算 \tilde{q}_k : $2(k-1)m$ flops. $\tilde{q}_k = a_k - a_k^T q_1 q_1 - a_k^T q_2 q_2 - \dots - a_k^T q_{k-1} q_{k-1}$
- 计算 R_{kk} 和 q_k : $3m$ flops. $R_{kk} = \|\tilde{q}_k\|_2$, $q_k = \tilde{q}_k / R_{kk}$

第k次循环的总和: $(4m-1)(k-1) + 3m$ flops

- $A \in \mathbb{R}^{m \times n}$ 分解的复杂度:

$$\begin{aligned} \sum_{k=1}^n ((4m-1)(k-1) + 3m) &= (4m-1) \frac{n(n-1)}{2} + 3mn \\ &\approx 2mn^2 \text{ flops} \end{aligned}$$

9.11.3 数值实验

- GS的MATLAB代码:

```
[m, n] = size(A);
Q = zeros(m,n);
R = zeros(n,n);
for k = 1:n
    R(1:k-1,k) = Q(:,1:k-1)' * A(:,k);
    v = A(:,k) - Q(:,1:k-1) * R(1:k-1,k);
    R(k,k) = norm(v);
    Q(:,k) = v / R(k,k);
end;
```


- 矩阵A的构造: $A = USV$, 其中U和V是正交矩阵, S是对角矩阵, 即:

$$S_{ii} = 10^{-10(i-1)/(n-1)}, \quad i = 1, \dots, n.$$

- 把GS应用到一个大小为 $m = n = 50$ 的方形矩阵A上。

9.11.3 数值实验

- 图中显示了 q_k 与前面列之间的正交性的偏差:



- 注: 失去正交性是由于浮点数存储的舍入误差。

9.12 Householder算法

- Householder算法**是QR分解常用的算法(MATLAB和Julia中的qr函数);
- 与Gram-Schmidt相比, 对舍入误差更有鲁棒性;
- 计算一个“完整的”QR因数分解:

$$A = [Q \quad \tilde{Q}] \begin{bmatrix} R \\ 0 \end{bmatrix}, \quad [Q \quad \tilde{Q}] \text{ 是正交的矩阵}$$

- 完整的Q因子被构造成正交矩阵的乘积:


$$[Q \quad \tilde{Q}] = H_1 H_2 \cdots H_n$$

每个 $H_i \in \mathbb{R}^{m \times m}$ 是对称的正交的“反射算子”(reflector)。

9.12.1 反射算子

$$H = I - 2vv^T \quad \text{其中} \|v\|_2 = 1$$

- Hx 是 x 关于超平面 $\{u | v^T u = 0\}$ 反对称



9.12.1 反射算子

$$H = I - 2vv^T \quad \text{其中} \|v\|_2 = 1$$

- Hx 是 x 关于超平面 $\{u | v^T u = 0\}$ 反对称
- H 是对称: $H^T = H$
- H 是正交: $H^T H = I$
- 矩阵向量积 Hx 能化简为:

$$Hx = x - 2(v^T x)v$$

如果 v 和 x 的长度是 p , 复杂度是 $4p$ flops。

9.12.2 构造反射算子

给定非零 p 维向量 $y = (y_1, y_2, \dots, y_p)$, 定义:

$$w = \begin{bmatrix} y_1 + \text{sign}(y_1)\|y\|_2 \\ y_2 \\ \vdots \\ y_p \end{bmatrix}, \quad v = \frac{w}{\|w\|_2}, \quad \begin{matrix} \text{sign}(y_1) = 1, y_1 \geq 0; \\ \text{sign}(y_1) = -1, y_1 < 0 \end{matrix}$$


■ 向量 w 满足:

$$\|w\|_2^2 = w^T w = 2(\|y\|_2^2 + |y_1|\|y\|_2) = 2y^T (y + \text{sign}(y_1)\|y\|_2 e_1) = 2y^T w$$

■ 反射算子 $H = I - 2vv^T = I - 2\frac{ww^T}{\|w\|_2^2}$ 将 y 映射为:

$$Hy = y - \frac{2(w^T y)}{\|w\|_2^2} w = y - w = -\text{sign}(y_1)\|y\|_2 e_1 = \begin{bmatrix} -\text{sign}(y_1)\|y\|_2 \\ 0 \\ \vdots \\ 0 \end{bmatrix}$$

9.12.3 几何意义



■ 关于超平面 $\{x | w^T x = 0\}$, 其法向量:

$$v = \frac{w}{\|w\|_2}, \quad w = y + \text{sign}(y_1)\|y\|_2 e_1$$

反射算子将 y 映射到向量 $-\text{sign}(y_1)\|y\|_2 e_1$ 。


9.12.5 Householder算法

■ 下面的算法用 $\begin{bmatrix} R \\ 0 \end{bmatrix}$ 来代替 $A \in \mathbb{R}^{m \times n}$

■ Householder算法步骤: (k从1到n)

1. 令 $y = A_{k:m,k} \in \mathbb{R}^{m-k+1}$, 计算向量 v_k :

$$w = y + \text{sign}(y_1)\|y\|_2 e_1, \quad v_k = \frac{1}{\|w\|_2} w$$




2. 将 $A_{k:m,k:n} \in \mathbb{R}^{(m-k+1) \times (n-k+1)}$ 与反射算子 $I - 2v_k v_k^T$ 相乘:

$$A_{k:m,k:n} := A_{k:m,k:n} - 2v_k (v_k^T A_{k:m,k:n})$$

9.12.5 Householder算法注解

■ 在步骤2中, 将 $A_{k:m,k:n}$ 与反射算子 $I - 2v_k v_k^T$ 相乘:

$$(I - 2v_k v_k^T) A_{k:m,k:n} = A_{k:m,k:n} - 2v_k (v_k^T A_{k:m,k:n})$$



■ 等价于用 $H_k \in \mathbb{R}^{m \times m}$ 乘以 A :

$$H_k = \begin{bmatrix} I & 0 \\ 0 & I - 2v_k v_k^T \end{bmatrix} = I - 2 \begin{bmatrix} 0 \\ v_k \end{bmatrix} \begin{bmatrix} 0 & v_k^T \end{bmatrix}$$

■ 算法将下列矩阵来代替 A :

$$\begin{bmatrix} R \\ 0 \end{bmatrix}$$

I	0
0	$I - 2v_k v_k^T$

返回(return)向量 v_1, \dots, v_n , 其中 v_k 的长度为 $m-k+1$ 。

9.12.6 例子

R的**第一列**:

■ 计算将A的第一列映射到 e_1 乘积的反射算子:

$$y = \begin{bmatrix} -1 \\ 1 \\ -1 \\ 1 \end{bmatrix}, \quad w = y - \|y\|_2 e_1 = \begin{bmatrix} -3 \\ 1 \\ -1 \\ 1 \end{bmatrix}, \quad v_1 = \frac{1}{\|w\|_2} w = \frac{1}{2\sqrt{3}} \begin{bmatrix} -3 \\ 1 \\ -1 \\ 1 \end{bmatrix}$$

■ 用 $I_4 - 2v_1v_1^T$ 和A的乘积代替A:

$$A := (I_4 - 2v_1v_1^T)A = \begin{bmatrix} 2 & 4 & 2 \\ 0 & 4/3 & 8/3 \\ 0 & 2/3 & 16/3 \\ 0 & 4/3 & 20/3 \end{bmatrix}$$

9.12.6 例子

R的**第二列**:

■ 计算将 $A_{2:4,2}$ 映射到 e_1 乘积的反射器:

$$y = \begin{bmatrix} 4/3 \\ 2/3 \\ 4/3 \end{bmatrix}, \quad w = y + \|y\|_2 e_1 = \begin{bmatrix} 10/3 \\ 2/3 \\ 4/3 \end{bmatrix}, \quad v_2 = \frac{1}{\|w\|_2} w = \frac{1}{\sqrt{30}} \begin{bmatrix} 5 \\ 1 \\ 2 \end{bmatrix}$$

■ 用 $I_3 - 2v_2v_2^T$ 和 $A_{2:4,2:3}$ 的乘积代替 $A_{2:4,2:3}$:

$$A := \begin{bmatrix} 1 & 0 \\ 0 & I_3 - 2v_2v_2^T \end{bmatrix} A = \begin{bmatrix} 2 & 4 & 2 \\ 0 & -2 & -8 \\ 0 & 0 & 16/5 \\ 0 & 0 & 12/5 \end{bmatrix}$$

9.12.6 例子

■ 最终结果:

$$\begin{aligned} H_3 H_2 H_1 A &= \begin{bmatrix} I_2 & 0 \\ 0 & I_2 - 2v_3v_3^T \end{bmatrix} \begin{bmatrix} I_1 & 0 \\ 0 & I_3 - 2v_2v_2^T \end{bmatrix} (I_4 - 2v_1v_1^T) A \\ &= \begin{bmatrix} I_2 & 0 \\ 0 & I_2 - 2v_3v_3^T \end{bmatrix} \begin{bmatrix} I_1 & 0 \\ 0 & I_3 - 2v_2v_2^T \end{bmatrix} \begin{bmatrix} 2 & 4 & 2 \\ 0 & 4/3 & 8/3 \\ 0 & 2/3 & 16/3 \\ 0 & 4/3 & 20/3 \end{bmatrix} \\ &= \begin{bmatrix} I_2 & 0 \\ 0 & I_2 - 2v_3v_3^T \end{bmatrix} \begin{bmatrix} 2 & 4 & 2 \\ 0 & -2 & -8 \\ 0 & 0 & 16/5 \\ 0 & 0 & 12/5 \end{bmatrix} \\ &= \begin{bmatrix} 2 & 4 & 2 \\ 0 & -2 & -8 \\ 0 & 0 & -4 \\ 0 & 0 & 0 \end{bmatrix} \end{aligned}$$

9.12.7 时间复杂度

$$(I - 2v_k v_k^T) A_{k:m,k:n} = A_{k:m,k:n} - 2v_k (v_k^T A_{k:m,k:n})$$

Householder方法第k次循环的复杂度:

■ $v_k^T A_{k:m,k:n}$ 的乘积: $(2(m-k+1)-1)(n-k+1)$ flops.


■ v_k 的外积: $(m-k+1)(n-k+1)$ flops.

■ $A_{k:m,k:n}$ 的减法: $(m-k+1)(n-k+1)$ flops.

第k次循环的总和: $4(m-k+1)(n-k+1)$ flops

■ 计算R和 v_1, \dots, v_n 的总复杂度:

$$\begin{aligned} \sum_{k=1}^n 4(m-k+1)(n-k+1) &\approx \int_0^n 4(m-t)(n-t+1) dt \\ &\approx 2mn^2 - \frac{2}{3}n^3 \text{ flops} \end{aligned}$$



10.2 QR分解求解线性方程组

- 使用QR分解求解线性方程组 $Ax = b$, 矩阵 $A \in \mathbb{R}^{n \times n}$ 为非奇异矩阵
 - 1. 首先对 A 进行QR分解, 得到 $A = QR$
 - 2. 计算 $y = Q^T b$
 - 3. 通过回代法求解 $Rx = y$
- 复杂度: $2n^3 + 3n^2 \approx 2n^3$ flops
 - QR分解复杂度: $2n^3$
 - 矩阵向量乘法: $2n^2$
 - 回代法: n^2

10.2应用QR分解

- 计算非奇异矩阵 $A \in \mathbb{R}^{n \times n}$ 的逆 A^{-1} , 通过 $AX = I$, 即 $QRX = I$.

$$X = [x_1, x_2, \dots, x_n], x_i \in \mathbb{R}^n, i = 1, \dots, n.$$

$$I = [e_1, e_2, \dots, e_n], e_i \in \mathbb{R}^n, i = 1, \dots, n.$$

$$QRX = I \Rightarrow RX = Q^T I$$

$$Rx_1 = Q^T e_1, Rx_2 = Q^T e_2, \dots, Rx_n = Q^T e_n$$
- 复杂度: $2n^3 + n^3 \approx 3n^3$ flops
 - QR分解复杂度: $2n^3$
 - 回代法: 一次回代 n^2 , 则 n 次回代 n^3

10.3 LU分解

- $A = LU$ 分解
 - L 为下三角矩阵并且 **对角线元素全为1**, U 为上三角矩阵。

$$A = \begin{pmatrix} a_{11} & \cdots & a_{1k} & \cdots & a_{1n} \\ \vdots & & \vdots & & \vdots \\ a_{k1} & \cdots & a_{kk} & \cdots & a_{kn} \\ \vdots & & \vdots & & \vdots \\ a_{n1} & \cdots & a_{nk} & \cdots & a_{nn} \end{pmatrix} = LU$$

$$L = \begin{pmatrix} 1 & 0 & \cdots & 0 \\ l_{21} & 1 & \ddots & 0 \\ \vdots & \vdots & \ddots & 0 \\ l_{n1} & l_{n2} & \cdots & 1 \end{pmatrix} \quad U = \begin{pmatrix} u_{11} & u_{12} & \cdots & u_{1n} \\ 0 & u_{22} & \cdots & u_{2n} \\ \vdots & 0 & \ddots & \vdots \\ 0 & 0 & 0 & u_{nn} \end{pmatrix}$$

10.3 LU分解

$$A = \begin{pmatrix} a_{11} & \cdots & a_{1r} & \cdots & a_{1n} \\ \vdots & & \vdots & & \vdots \\ a_{r1} & \cdots & a_{rr} & \cdots & a_{rn} \\ \vdots & & \vdots & & \vdots \\ a_{n1} & \cdots & a_{nr} & \cdots & a_{nn} \end{pmatrix} = \begin{pmatrix} 1 & 0 & 0 & \cdots & 0 \\ \vdots & \ddots & 0 & \ddots & 0 \\ l_{r1} & \cdots & 1 & \ddots & \vdots \\ \vdots & \vdots & \vdots & \ddots & 0 \\ l_{n1} & \cdots & l_{nr} & \cdots & 1 \end{pmatrix} \cdot \begin{pmatrix} u_{11} & \cdots & u_{1r} & \cdots & u_{1n} \\ 0 & \ddots & \vdots & \ddots & \vdots \\ 0 & 0 & u_{rr} & \cdots & u_{rn} \\ \vdots & \ddots & \vdots & \ddots & \vdots \\ 0 & \cdots & 0 & 0 & u_{nn} \end{pmatrix}$$

U 的**第一行**元素 u_{1j} 为

$$a_{1j} = u_{1j} \Rightarrow u_{1j} = a_{1j}, j = 1, \dots, n.$$

L 的**第一列**元素 l_{i1} 为

$$l_{i1} = \frac{a_{i1}}{u_{11}} \quad i = 2, 3, \dots, n.$$

U 第 **r** 行主对角线以右元素 u_{rj}

$$u_{rj} = a_{rj} - \sum_{k=1}^{r-1} l_{rk} u_{kj} \quad j = r, \dots, n.$$

L 第 **r** 列主对角线以下元素 l_{ir}

$$l_{ir} = \frac{a_{ir} - \sum_{k=1}^{r-1} l_{ik} u_{kr}}{u_{rr}} \quad i = r + 1, \dots, n.$$

10.4 LU复杂度

■ 求解 $Ax = b$, A 为非奇异矩阵

■ 1. 对矩阵 A 进行LU分解 ($\frac{2}{3}n^3 \text{ flops}$)

■ 2. 回代法: 求解 $Ly = b$ ($n^2 \text{ flops}$)

■ 3. 回代法: 求解 $Ux = y$ ($n^2 \text{ flops}$)

■ 复杂度: $\frac{2}{3}n^3 + 2n^2 \approx \frac{2}{3}n^3 \text{ flops}$

■ LU算法为求解方程组 $Ax = b$ 的标准解法

10.7 例子

$$A = \begin{bmatrix} 8 & 2 & 9 \\ 4 & 9 & 4 \\ 6 & 7 & 9 \end{bmatrix} = \begin{bmatrix} 1 & 0 & 0 \\ l_{21} & 1 & 0 \\ l_{31} & l_{32} & 1 \end{bmatrix} \begin{bmatrix} u_{11} & u_{12} & u_{13} \\ 0 & u_{22} & u_{23} \\ 0 & 0 & u_{33} \end{bmatrix}$$

■ 计算 U 的第一行和 L 的第一列

$$(u_{11}, u_{12}, u_{13}) = (8, 2, 9) \quad (l_{21}, l_{31}) = \left(\frac{1}{2}, \frac{3}{4}\right)$$

■ 然后计算 U 的第二行和 L 的第二列

$$u_{22} = a_{22} - l_{21}u_{12} = 8 \quad u_{23} = a_{23} - l_{21}u_{13} = -\frac{1}{2}$$

$$l_{32} = \frac{a_{32} - l_{31}u_{12}}{u_{22}} = \frac{11}{16}$$

$$u_{33} = a_{33} - l_{31}u_{13} - l_{32}u_{23} = -\frac{83}{32}$$

$$u_{rj} = a_{rj} - \sum_{k=1}^{r-1} l_{rk}u_{kj}$$

$$l_{ir} = \frac{a_{ir} - \sum_{k=1}^{r-1} l_{ik}u_{kr}}{u_{rr}}$$

■ 最后计算 U 的第三行


11.2 最小二乘法

给定 $A \in \mathbb{R}^{m \times n}$, $b \in \mathbb{R}^m$, 求解 $x \in \mathbb{R}^n$ 让目标函数最小:

$$\min_x \|Ax - b\|_2^2 = \min_x \sum_{i=1}^m \left(\sum_{j=1}^n A_{ij}x_j - b_i \right)^2$$

例如: $f(x) = \|Ax - b\|_2^2$,

$$A = \begin{bmatrix} 2 & 0 \\ -1 & 1 \\ 0 & 2 \end{bmatrix}, b = \begin{bmatrix} 1 \\ 0 \\ -1 \end{bmatrix}$$



$$f(x) = \|Ax - b\|_2^2 = (2x_1 - 1)^2 + (-x_1 + x_2)^2 + (2x_2 + 1)^2$$

$$\frac{\partial f}{\partial x_1} = 10x_1 - 2x_2 - 4$$

$$\frac{\partial f}{\partial x_2} = -2x_1 + 10x_2 + 4$$

$$\nabla f(x) = \begin{bmatrix} \frac{\partial f}{\partial x_1} \\ \frac{\partial f}{\partial x_2} \end{bmatrix} = 0 \Rightarrow \hat{x} = \left(\frac{1}{3}, -\frac{1}{3}\right)^T$$

11.7 正规方程

$$A^T Ax = A^T b$$

■ 最小二乘法问题的正规方程

■ 系数矩阵 $A^T A$ 是 A 的 Gram 矩阵

■ 等价于 " $\nabla f(x) = 0, f(x) = \|Ax - b\|_2^2$ "

■ 最小二乘法问题所有的解都满足正规方程

■ 如果 A 的列线性无关, 则

■ $A^T A$ 为非奇异矩阵

■ 正规方程此时有唯一解

11.8 QR分解求解

- 若 $A \in \mathbb{R}^{m \times n}$ 的列向量线性无关，则存在 $A=QR$ 分解， $Q \in \mathbb{R}^{m \times n}$ ， $R \in \mathbb{R}^{n \times n}$ 最小二乘法问题的解：

$$\begin{aligned}\hat{x} &= (A^T A)^{-1} A^T b = ((QR)^T (QR))^{-1} (QR)^T b \\ &= (R^T Q^T Q R)^{-1} R^T Q^T b \\ &= (R^T R)^{-1} R^T Q^T b \\ &= R^{-1} Q^T b\end{aligned}$$

- 算法复杂度：
 - 首先对A进行QR分解 $A = QR$ ($2mn^2$ flops)
 - 计算矩阵向量乘积 $d = Q^T b$ ($2mn$ flops)
 - 通过回代求解 $Rx = d$ (n^2 flops)
 - 复杂度： $2mn^2$ flops

11.9 例子

$$A = \begin{bmatrix} 3 & -6 \\ 4 & -8 \\ 0 & 1 \end{bmatrix}, \quad b = \begin{bmatrix} -1 \\ 7 \\ 0 \end{bmatrix}$$

- 1. 首先对A进行QR分解

$$Q = \begin{bmatrix} 3/5 & 0 \\ 4/5 & 0 \\ 0 & 1 \end{bmatrix}, \quad R = \begin{bmatrix} 5 & -10 \\ 0 & 1 \end{bmatrix}$$

- 2. 计算 $d = Q^T b = (5, 0)$
- 3. 求解 $Rx = d$

$$\begin{bmatrix} 5 & -10 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} 5 \\ 0 \end{bmatrix}$$

- 4. 解的 $x_1 = 1, x_2 = 0$

11.10 梯度下降法

- 设函数 $f(x)$ 可微，根据泰勒公式，在 $x^{(k)}$ 的一阶公式为

$$f(x^{(k+1)}) \approx f(x^{(k)}) + \langle \nabla f(x^{(k)}), x^{(k+1)} - x^{(k)} \rangle + o(\|x^{(k+1)} - x^{(k)}\|).$$

- 如果 $\|x^{(k+1)} - x^{(k)}\|_2$ 足够小，则有

$$f(x^{(k+1)}) - f(x^{(k)}) \approx \langle \nabla f(x^{(k)}), x^{(k+1)} - x^{(k)} \rangle.$$

- 根据柯西不等式， $|\langle \nabla f(x^{(k)}), x^{(k+1)} - x^{(k)} \rangle| \leq \|\nabla f(x^{(k)})\|_2 \|x^{(k+1)} - x^{(k)}\|_2$,

$$\langle \nabla f(x^{(k)}), x^{(k+1)} - x^{(k)} \rangle \geq -\|\nabla f(x^{(k)})\|_2 \|x^{(k+1)} - x^{(k)}\|_2,$$

当 $x^{(k+1)} - x^{(k)} = -\alpha_k \nabla f(x^{(k)})$ ， $\alpha_k > 0$ 时，等式成立。

$$\text{迭代公式: } x^{(k+1)} = x^{(k)} - \alpha_k \nabla f(x^{(k)}). \quad f(x^{(k+1)}) < f(x^{(k)}).$$

11.10 梯度下降法

$$\min_{x \in \mathbb{R}^n} \frac{1}{2} \|Ax - b\|_2^2, \quad A \in \mathbb{R}^{m \times n}, b \in \mathbb{R}^m$$

- 令 $f(x) = \frac{1}{2} \|Ax - b\|_2^2$ ，则 f 为凸函数，并有 $\nabla f(x) = A^T(Ax - b)$
- 则 $A^T A \in \mathbb{R}^{n \times n}$ ，“列向量线性相关”导致其不可逆或 n 非常大！
- 通过梯度下降法迭代求解， $x^{(k+1)} = x^{(k)} - \alpha^{(k)} A^T(Ax^{(k)} - b)$
- 为了估计 $\alpha^{(k)}$ ，通过线性搜索估计：

$$\alpha^{(k)} = \operatorname{argmin}_{\alpha \in \mathbb{R}} f(x^{(k)} - \alpha A^T(Ax^{(k)} - b)).$$

即 $\alpha^{(k)}$ 是最优步长。令 $g(\alpha) = f(x^{(k)} - \alpha A^T(Ax^{(k)} - b))$ 是关于 α 的凸函数，则有

$$\min_{\alpha} g(\alpha) \Rightarrow g'(\alpha) = 0 \Rightarrow \alpha^{(k)} = \frac{\|A^T(Ax^{(k)} - b)\|_2^2}{\|AA^T(Ax^{(k)} - b)\|_2^2}.$$

11.10 梯度下降法

$$\min_{x \in \mathbb{R}^n} \frac{1}{2} \|Ax - b\|_2^2, \quad A \in \mathbb{R}^{m \times n}, b \in \mathbb{R}^m$$

梯度下降法求解最小二乘法

作业 12.3 12.8

1. 初始 $x^{(0)}$
2. for $k=0, 1, \dots$, do

$$p^{(k)} = A^T(Ax^{(k)} - b)$$

$$\alpha^{(k)} = \frac{\|p^{(k)}\|_2^2}{\|Ap^{(k)}\|_2^2}$$

$$x^{(k+1)} = x^{(k)} - \alpha^{(k)} p^{(k)}$$

当满足迭代条件，则退出。

13.1 KKT条件：例子

$$\max_x \{f(x) = 20x_1 + 10x_2\}$$

$$s.t. \quad g_1(x) = x_1^2 + x_2^2 \leq 1, g_2(x) = x_1 + 2x_2 \leq 2,$$

$$g_3(x) = -x_1 \leq 0, g_4(x) = -x_2 \leq 0$$

$$\nabla_x L(x, u) = \nabla_x f(x) - u_1 \nabla_x g_1(x) - u_2 \nabla_x g_2(x) - u_3 \nabla_x g_3(x) - u_4 \nabla_x g_4(x) = 0, u_j \geq 0$$

$$\nabla_x f(x) = \begin{bmatrix} 20 \\ 10 \end{bmatrix}, \nabla_x g_1(x) = \begin{bmatrix} 2x_1 \\ 2x_2 \end{bmatrix}, \nabla_x g_2(x) = \begin{bmatrix} 1 \\ 2 \end{bmatrix}, \nabla_x g_3(x) = \begin{bmatrix} -1 \\ 0 \end{bmatrix}, \nabla_x g_4(x) = \begin{bmatrix} 0 \\ -1 \end{bmatrix}.$$


检测 $g_1(x)$ 边界

检测 $g_2(x)$ 边界

检测 $g_3(x)$ 边界

检测 $g_4(x)$ 边界

$$\nabla_x f(x) = u_1 \nabla_x g_1(x), \nabla_x f(x) \neq u_2 \nabla_x g_2(x), \nabla_x f(x) \neq u_3 \nabla_x g_3(x), \nabla_x f(x) \neq u_4 \nabla_x g_4(x).$$



$$u_2 = u_3 = u_4 = 0, u_1 \neq 0.$$

13.1 KKT条件：例子


$$\max_x \{f(x) = 20x_1 + 10x_2\}$$

$$s.t. \quad g_1(x) = x_1^2 + x_2^2 \leq 1, g_2(x) = x_1 + 2x_2 \leq 2,$$

$$g_3(x) = -x_1 \leq 0, g_4(x) = -x_2 \leq 0$$

$$\text{即 } \nabla_x f(x) = u_1 \nabla_x g_1(x), \begin{bmatrix} 20 \\ 10 \end{bmatrix} = u_1 \begin{bmatrix} 2x_1 \\ 2x_2 \end{bmatrix} \Rightarrow x_1 = 2x_2, \text{ 代入 } g_1(x) = x_1^2 + x_2^2 - 1 = 5x_2^2 - 1 = 0.$$

$$\text{由于 } x_2 \geq 0, \text{ 可得 } \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \frac{\sqrt{5}}{5} \begin{bmatrix} 2 \\ 1 \end{bmatrix}, u_1 = 5\sqrt{5}.$$



13.2 最小范数优化问题

$$\min_x \frac{1}{2} \|x\|_2^2$$

$$s.t. \quad Cx = d,$$

引入拉格朗日函数：

$$L(x, \lambda) = \frac{1}{2} \|x\|_2^2 - \lambda^T (Cx - d)$$

对拉格朗日函数求导：

$$\nabla_x L(x, \lambda) = x - C^T \lambda = 0 \Rightarrow x = C^T \lambda$$

"矩阵 C 行线性无关" 可得：

$$Cx = CC^T \lambda = d \Rightarrow \lambda = (CC^T)^{-1} d$$

则有：

$$\hat{x} = C^T \lambda = C^T (CC^T)^{-1} d = C^\dagger d.$$

13.2 验证最优解

- 1. 首先证明解 \hat{x} 满足等式 $\hat{x} = C^T \lambda = C^T (CC^T)^{-1} d = C^\dagger d$.

$$C\hat{x} = CC^T (CC^T)^{-1} d = d$$

- 2. 在 $Cx = d$, $x \neq \hat{x}$ 的情况下,

$$\begin{aligned}\hat{x}^T (x - \hat{x}) &= d^T (CC^T)^{-1} C(x - \hat{x}) \\ &= d^T (CC^T)^{-1} (Cx - C\hat{x}) \\ &= d^T (CC^T)^{-1} (d - d) \\ &= 0\end{aligned}$$

- 3. 在 $Cx = d$, $x \neq \hat{x}$ 的情况下, 证明 $\|x\|_2^2 > \|\hat{x}\|_2^2$

$$\begin{aligned}\|x\|_2^2 &= \|x - \hat{x} + \hat{x}\|_2^2 \\ &= \|\hat{x}\|_2^2 + 2\hat{x}^T (x - \hat{x}) + \|x - \hat{x}\|_2^2 \\ &= \|\hat{x}\|_2^2 + \|x - \hat{x}\|_2^2 \\ &> \|\hat{x}\|_2^2\end{aligned}$$

13.2 QR分解求解

- 对矩阵 $C^T \in \mathbb{R}^{n \times p}$ 进行QR分解, $C^T = QR$

$$\begin{aligned}\hat{x} &= C^T (CC^T)^{-1} d \\ &= QR(R^T Q^T QR)^{-1} d \\ &= QR(R^T R)^{-1} d \\ &= QR^{-T} d\end{aligned}$$

- 复杂度:

- 1. 矩阵 $C^T = QR$ 分解, $C^T = QR(2np^2 \text{ flops})$
- 2. 回代法求解 $R^T z = d$ ($p^2 \text{ flops}$)
- 3. 计算 $\hat{x} = Qz(2np \text{ flops})$
- 总复杂度: ($\approx 2np^2 \text{ flops}$)

13.2 例子

$$C = \begin{bmatrix} 1 & -1 & 1 & 1 \\ 1 & 0 & 1/2 & 1/2 \end{bmatrix}, \quad d = \begin{bmatrix} 0 \\ 1 \end{bmatrix}$$

- 对矩阵 C^T 进行QR分解, $C^T = QR$

$$\begin{bmatrix} 1 & 1 \\ -1 & 0 \\ 1 & 1/2 \\ 1 & 1/2 \end{bmatrix} = \begin{bmatrix} 1/2 & 1/\sqrt{2} \\ -1/2 & 1/\sqrt{2} \\ 1/2 & 0 \\ 1/2 & 0 \end{bmatrix} \begin{bmatrix} 2 & 1 \\ 0 & 1/\sqrt{2} \end{bmatrix}$$

- 通过回代法求解 $R^T z = d$

$$\begin{bmatrix} 2 & 0 \\ 1 & 1/\sqrt{2} \end{bmatrix} \begin{bmatrix} z_1 \\ z_2 \end{bmatrix} = \begin{bmatrix} 0 \\ 1 \end{bmatrix}$$

- 解 $z_1 = 0, z_2 = \sqrt{2}$
- 得 $\hat{x} = Qz = (1, 1, 0, 0)$

13.3 分段多项式拟合问题


- 两个多项式 $f(x), g(x)$ 对于样本点 $(x_1, y_1), \dots, (x_N, y_N)$ 进行拟合

$$f(x_i) \approx y_i, x_i \leq a$$

$$g(x_i) \approx y_i, x_i > a$$

- 拟合要求: 函数值和导数值必须在分段位置 a 连续

$$f(a) = g(a), f'(a) = g'(a)$$



13.3分段多项式拟合问题

- 假设样本点 $(x_1, y_1), \dots, (x_N, y_N) \in \mathbb{R}^2$, 有 $x_1, \dots, x_M \leq a$, $x_{M+1}, \dots, x_N > a$;

- d阶多项式 $f(x) = \theta_1 + \theta_2 x + \dots + \theta_d x^{d-1}$,
 $g(x) = \theta_{d+1} + \theta_{d+2} x + \dots + \theta_{2d} x^{d-1}$;

$$A = \begin{bmatrix} 1 & x_1 & \dots & x_1^{d-1} & 0 & 0 & \dots & 0 \\ \vdots & \vdots & \vdots & \vdots & \vdots & \vdots & \vdots & \vdots \\ 1 & x_M & \dots & x_M^{d-1} & 0 & 0 & \dots & 0 \\ \hline 0 & 0 & \dots & 0 & 1 & x_{M+1} & \dots & x_{M+1}^{d-1} \\ \vdots & \vdots & \vdots & \vdots & \vdots & \vdots & \vdots & \vdots \\ 0 & 0 & \dots & 0 & 1 & x_N & \dots & x_N^{d-1} \end{bmatrix}, \theta = \begin{bmatrix} \theta_1 \\ \vdots \\ \theta_d \\ \theta_{d+1} \\ \vdots \\ \theta_{2d} \end{bmatrix}, b = \begin{bmatrix} y_1 \\ \vdots \\ y_M \\ y_{M+1} \\ \vdots \\ y_N \end{bmatrix},$$

$$A\theta \approx b$$

参数 θ 需要确定?

$$\min_{\theta} \|A\theta - b\|_2^2$$

13.3分段多项式拟合问题

- 假设样本点 $(x_1, y_1), \dots, (x_N, y_N) \in \mathbb{R}^2$, 有 $x_1, \dots, x_M \leq a$, $x_{M+1}, \dots, x_N > a$;

- d阶多项式 $f(x) = \theta_1 + \theta_2 x + \dots + \theta_d x^{d-1}$,
 $g(x) = \theta_{d+1} + \theta_{d+2} x + \dots + \theta_{2d} x^{d-1}$;

- 约束条件: $f(a) = g(a), f'(a) = g'(a)$ $\theta = \begin{bmatrix} \theta_1 \\ \vdots \\ \theta_d \\ \theta_{d+1} \\ \vdots \\ \theta_{2d} \end{bmatrix}$

$$C = \begin{bmatrix} 1 & a & \dots & a^{d-1} & -1 & -a & \dots & -a^{d-1} \\ 0 & 1 & \dots & (d-1)a^{d-2} & 0 & -1 & \dots & -(d-1)a^{d-2} \end{bmatrix}, d = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$$

$$C\theta = d$$

13.3分段多项式拟合问题

- 假设样本点 $(x_1, y_1), \dots, (x_N, y_N) \in \mathbb{R}^2$, 有 $x_1, \dots, x_M \leq a$, $x_{M+1}, \dots, x_N > a$;

- d阶多项式 $f(x) = \theta_1 + \theta_2 x + \dots + \theta_d x^{d-1}$,
 $g(x) = \theta_{d+1} + \theta_{d+2} x + \dots + \theta_{2d} x^{d-1}$;

- 约束条件: $f(a) = g(a), f'(a) = g'(a)$

$$\min_{\theta} \sum_{i=1}^M (f(x_i) - y_i)^2 + \sum_{i=M+1}^N (g(x_i) - y_i)^2$$

$$s.t. \quad f(a) = g(a), f'(a) = g'(a)$$

$$\min_{\theta} \|A\theta - b\|_2^2$$

$$s.t. \quad C\theta = d$$

13.4 先验假设

$$\min_x \|Ax - b\|_2^2$$

$$s.t. \quad Cx = d$$

- 1. 堆叠矩阵列线性无关

$$\begin{bmatrix} A \\ C \end{bmatrix} \in \mathbb{R}^{(m+p) \times n}$$


- 2. 矩阵 $C \in \mathbb{R}^{p \times n}$ 行线性无关

- 假设“条件1”是一个比 A 可右逆更弱的条件

- $p \leq n \leq m + p$

13.4 最小二乘法约束KKT条件

$$\min_x \frac{1}{2} \|Ax - b\|_2^2$$



引入拉格朗日函数: $s.t. \quad Cx = d$

$$L(x, z) = \frac{1}{2} \|Ax - b\|_2^2 - z^T (d - Cx), z \in \mathbb{R}^p$$

对拉格朗日函数求导:

$$\nabla_x L(x, z) = A^T (Ax - b) + C^T z = 0$$

$$\nabla_z L(x, z) = Cx - d = 0$$

$$\begin{bmatrix} A^T A & C^T \\ C & 0 \end{bmatrix} \begin{bmatrix} x \\ z \end{bmatrix} = \begin{bmatrix} A^T b \\ d \end{bmatrix}$$

13.4 KKT最优条件

■ 令 \hat{x} 是约束优化问题的解, 则有

$$\begin{bmatrix} A^T A & C^T \\ C & 0 \end{bmatrix} \begin{bmatrix} \hat{x} \\ z \end{bmatrix} = \begin{bmatrix} A^T b \\ d \end{bmatrix}, \begin{bmatrix} \hat{x} \\ z \end{bmatrix} \in \mathbb{R}^{n+p}$$

■ 优化条件Karush-Kuhn-Tucker(KKT)等式

■ 特殊情况

- 最小二乘法问题: 当 $p = 0$ 时, 即为正规方程 $A^T A \hat{x} = A^T b$
- 最小范数问题: 当 $A = I, b = 0$ 时, 可以推导得到 $C\hat{x} = b, \hat{x} + C^T z = 0$

13.4 证明最优解

■ 假设 x 满足 $Cx = d, (\hat{x}, z)$ 满足KKT等式 $\begin{bmatrix} A^T A & C^T \\ C & 0 \end{bmatrix} \begin{bmatrix} \hat{x} \\ z \end{bmatrix} = \begin{bmatrix} A^T b \\ d \end{bmatrix}$

$$\begin{aligned} \|Ax - b\|_2^2 &= \|A(x - \hat{x}) + A\hat{x} - b\|_2^2 \\ &= \|A(x - \hat{x})\|_2^2 + \|A\hat{x} - b\|_2^2 + 2(x - \hat{x})^T A^T (A\hat{x} - b) \\ &= \|A(x - \hat{x})\|_2^2 + \|A\hat{x} - b\|_2^2 - 2(x - \hat{x})^T C^T z \\ &= \|A(x - \hat{x})\|_2^2 + \|A\hat{x} - b\|_2^2 \\ &\geq \|A\hat{x} - b\|_2^2 \end{aligned}$$

■ 第三行 $A^T A \hat{x} + C^T z = A^T b$

■ 第四行 $Cx = C\hat{x} = d \Rightarrow (x - \hat{x})^T C^T = (Cx - C\hat{x})^T = 0$

■ \hat{x} 是唯一性, 因为假设矩阵 A 列线性无关, C 行线性无关, 即

$$A^T A (\hat{x} - x) = 0 \Rightarrow x = \hat{x}$$

$$C^T (\hat{z} - z) = 0 \Rightarrow \hat{z} = z$$

$$A^T A \hat{x} + C^T z = A^T b$$

13.4 非奇异性

■ 如果矩阵 A 列线性无关, C 行线性无关, 则矩阵

$$\begin{bmatrix} A^T A & C^T \\ C & 0 \end{bmatrix}$$

为非奇异矩阵

■ 证明 $\begin{bmatrix} A^T A & C^T \\ C & 0 \end{bmatrix} \begin{bmatrix} x \\ z \end{bmatrix} = 0 \Rightarrow x^T (A^T Ax + C^T z) = 0, Cx = 0$

$$\Rightarrow \|Ax\|_2^2 + (Cx)^T z = \|Ax\|_2^2 = 0, \because Cx = 0$$

$$\Rightarrow Ax = 0, Cx = 0$$

$$\Rightarrow x = 0 \quad A \text{ 列线性无关}$$

由于 $A^T Ax + C^T z = 0$, 则当 $x = 0$ 时, 有 $z = 0$ 。

C 行线性无关

13.4 奇异性

- 如果矩阵A列线性无关和C行线性无关不同时成立，则矩阵

$$\begin{bmatrix} A^T A & C^T \\ C & 0 \end{bmatrix}$$

为奇异矩阵

- 如果A列线性相关，则存在 $x \neq 0$ ，使得 $Ax = 0$ ，则

$$\begin{bmatrix} A^T A & C^T \\ C & 0 \end{bmatrix} \begin{bmatrix} x \\ 0 \end{bmatrix} = 0$$

- 如果C行线性相关，则存在 $z \neq 0$ ，使得 $C^T z = 0$ ，则

$$\begin{bmatrix} A^T A & C^T \\ C & 0 \end{bmatrix} \begin{bmatrix} 0 \\ z \end{bmatrix} = 0$$

- 因此该矩阵为奇异矩阵

13.5 LU分解求解

$$\begin{bmatrix} A^T A & C^T \\ C & 0 \end{bmatrix} \begin{bmatrix} x \\ z \end{bmatrix} = \begin{bmatrix} A^T b \\ d \end{bmatrix}$$

$A \in \mathbb{R}^{m \times n}, C \in \mathbb{R}^{p \times n}, b \in \mathbb{R}^m, d \in \mathbb{R}^p$

算法：

- 计算 $H = A^T A$ ($2mn^2$ flops)。
- 计算 $c = A^T b$ ($2mn$ flops)。
- 用LU分解法求解下列线性方程 ($(2/3)(p+n)^3$ flops):

$$\begin{bmatrix} H & C^T \\ C & 0 \end{bmatrix} \begin{bmatrix} x \\ z \end{bmatrix} = \begin{bmatrix} c \\ d \end{bmatrix}$$

- 复杂度为: $2mn^2 + (2/3)(p+n)^3$ flops。

13.6 QR分解求解

由于 \hat{x} 满足 $C\hat{x} = d$ ，则有 $C^T C\hat{x} = C^T d$ ，可得

$$L(x, z) = \frac{1}{2} \|Ax - b\|_2^2 - z^T (d - Cx)$$

KKT条件: $\nabla_x L(x, z) = A^T (A\hat{x} - b) + C^T z + C^T C\hat{x} - C^T d = 0$

$$\Rightarrow (A^T A + C^T C)\hat{x} + C^T (z - d) = A^T b$$

$$\nabla_z L(x, z) = C\hat{x} - d = 0$$

- 令 $w = z - d$ ，KKT条件写成：

$$\begin{bmatrix} A^T A + C^T C & C^T \\ C & 0 \end{bmatrix} \begin{bmatrix} \hat{x} \\ w \end{bmatrix} = \begin{bmatrix} A^T b \\ d \end{bmatrix}$$

- 假设1保证了 $A^T A + C^T C$ 是非奇异的，即存在以下QR因子分解：

$$\begin{bmatrix} A \\ C \end{bmatrix} \text{列向量无关, 则 } \begin{bmatrix} A \\ C \end{bmatrix} = QR = \begin{bmatrix} Q_1 \\ Q_2 \end{bmatrix} R = \begin{bmatrix} Q_1 R \\ Q_2 R \end{bmatrix}$$

13.6 QR分解的解

$$\begin{bmatrix} A^T A + C^T C & C^T \\ C & 0 \end{bmatrix} \begin{bmatrix} \hat{x} \\ w \end{bmatrix} = \begin{bmatrix} A^T b \\ d \end{bmatrix}$$

代入QR分解，可得：

$$\begin{bmatrix} R^T R & R^T Q_2^T \\ Q_2^T R & 0 \end{bmatrix} \begin{bmatrix} \hat{x} \\ w \end{bmatrix} = \begin{bmatrix} R^T Q_1^T b \\ d \end{bmatrix}$$

- 将第一个方程两边乘 R^{-T} 和并令变量 $y = R\hat{x}$ 相乘，可得：

$$\begin{bmatrix} I & Q_2^T \\ Q_2 & 0 \end{bmatrix} \begin{bmatrix} y \\ w \end{bmatrix} = \begin{bmatrix} Q_1^T b \\ d \end{bmatrix}$$

- 矩阵 $C = Q_2 R \Rightarrow Q_2 = CR^{-1}$ ， Q_2 具有行线性无关：

$$Q_2^T u = R^{-T} C^T u = 0 \Rightarrow C^T u = 0 \Rightarrow u = 0$$

因为C行线性无关的(假设2)。

13.6 QR分解的解

利用 Q_2^T 的QR分解来求解：

$$\begin{bmatrix} I & Q_2^T \\ Q_2 & 0 \end{bmatrix} \begin{bmatrix} y \\ w \end{bmatrix} = \begin{bmatrix} Q_1^T b \\ d \end{bmatrix}$$

- 方程第1行可得 $y = Q_1^T b - Q_2^T w$ ，并代入第二行：

$$Q_2 y = d \Rightarrow Q_2 Q_2^T w = Q_2 Q_1^T b - d$$

- 用QR分解 $Q_2^T = \tilde{Q}\tilde{R}$ 来解这个关于 w 的方程：

$$\tilde{R}^T \tilde{R} w = \tilde{R}^T \tilde{Q}^T Q_1^T b - d$$

上式可以简化为：

$$\tilde{R} w = \tilde{Q}^T Q_1^T b - \tilde{R}^{-T} d$$

13.6 QR分解综述

$$\begin{bmatrix} A^T A + C^T C & C^T \\ C & 0 \end{bmatrix} \begin{bmatrix} \hat{x} \\ w \end{bmatrix} = \begin{bmatrix} A^T b \\ d \end{bmatrix} \quad \tilde{R} w = \tilde{Q}^T Q_1^T b - \tilde{R}^{-T} d$$

算法过程：

- 1. 计算两个QR分解：

$$\begin{bmatrix} A \\ C \end{bmatrix} = \begin{bmatrix} Q_1 \\ Q_2 \end{bmatrix} R, \quad Q_2^T = \tilde{Q}\tilde{R}$$

- 2. 用前代法求解 $\tilde{R}^T u = d$ ，计算 $c = \tilde{Q}^T Q_1^T b - u$ 。
- 3. 用回代法求解 $\tilde{R} w = c$ ，计算 $y = Q_1^T b - Q_2^T w$ 。
- 4. 用回代法计算 $R\hat{x} = y$ 。

复杂度：QR分解有 $2(p+m)n^2 + 2np^2$ 次flops。

13.6 复杂度QR vs LU

假设 $p < n$ ：

作业 16.11

- LU复杂度： $2mn^2 + (2/3)(p+n)^3 < 2mn^2 + (16/3)n^3$
- QR复杂度： $2(p+m)n^2 + 2np^2 < 2mn^2 + 4n^3$
- 稳定性：QR分解避免直接计算 $A^T A$ 。